

BM531 BÜYÜK VERİ ANALİTİĞİ FİNAL PROJE RAPORU



BERKANT KOZAN

25832901024

**GAZİ ÜNİVERSİTESİ
FEN BİLİMLERİ ENSTİTÜSÜ**

Büyük Veri Setlerinde Kopya ve Koordineli İçerik Tespiti: MinHash ve Yerel Duyarlı Hashing (LSH) Yaklaşımı	3
1. Özet (Abstract)	3
2. Giriş (Introduction)	3
3. Literatür Taraması (Literature Review).....	4
3.1. Büyük Veride Metin Benzerliği ve Brute-Force Sınırlamaları.....	4
3.2. MinHash ve LSH Teorisi: Jaccard ve Hız/Doğruluk Ödünleşimi	4
3.3. Haber ve Medya Verilerinde Koordineli/Kopya İçerik Tespiti	5
3.4. Model Değerlendirmesi, Ground Truth ve Metrikler (Precision/Recall/F1).....	5
4. Methodology	6
4.1. Ön İşleme ve K-Gram (Shingle) Üretimi.....	6
4.2. MinHash ile İmza Matrisinin (Signature Matrix) Oluşturulması.....	6
4.3. Yerel Duyarlı Hashing (LSH) ile Olasılıksal Filtreleme	7
4.4. Paralel Mimari ile Kesin Gerçeklik (Ground Truth) Analizi.....	7
5. Result and Discussion	8
5.1. Zaman Karmaşıklığı ve Başarım Takası (The Time-Accuracy Trade-off).....	9
5.2. Hata Analizi: Yanlış Negatifler (False Negatives)	9
5.3. Hata Analizi: Yanlış Pozitifler (False Positives)	9
5.4. Genel Değerlendirme	9
6. Limitations	10
7. Conclusion.....	10
8. Kaynakça	12
EKLER	13

Büyük Veri Setlerinde Kopya ve Koordineli İçerik Tespiti: MinHash ve Yerel Duyarlı Hashing (LSH) Yaklaşımı

1. Özet (Abstract)

Büyük hacimli metin veri setlerinde benzer veya tamamen kopyalanmış içeriklerin tespiti, $O(N^2)$ zaman karmaşıklığı nedeniyle geleneksel kaba kuvvet (brute-force) yöntemleriyle çözilemeyen temel bir veri madenciliği problemidir. Bu çalışmada, News Category Dataset v3 üzerinde (yaklaşık 210.000 belge) kopya ve koordineli haber içeriklerini tespit etmek amacıyla MinHash ve Yerel Duyarlı Hashing (LSH - Locality-Sensitive Hashing) algoritmalarına dayalı ölçeklenebilir bir veri boru hattı geliştirilmiştir. Geliştirilen sistemin doğruluğunu matematiksel olarak kanıtlamak için, 12 mantıksal iş parçacıklı paralel mimari kullanılarak veri setindeki tüm belgeler ($21.9 \cdot 10^9$ kombinasyon) kaba kuvvet yöntemiyle taranmış ve "Kesin Gerçeklik" (Ground Truth) matrisi elde edilmiştir. Değerlendirme sonucunda model; %88.49 Duyarlılık (Recall), %82.05 Kesinlik (Precision) ve %85.15 F1-Skoru elde etmiş olup, işlem süresini saatlerden saniyelere indirerek yüksek başarımlı göstermiştir.

2. Giriş (Introduction)

Doğal Dil İşleme (NLP) ve bilgi geri kazanımı alanlarında, belgeler arası anlamsal veya sözdizimsel benzerliklerin tespiti kritik bir rol oynamaktadır. Özellikle dijital habercilikte, aynı haberin farklı platformlarda koordineli olarak yayımlanması veya intihal yoluyla kopyalanması sık karşılaşılan bir durumdur. Belge benzerliğini ölçmek için sıklıkla kullanılan Jaccard Benzerliği, küçük veri setlerinde oldukça etkili sonuçlar verse de, veri boyutu yüz binlere ulaştığında donanım ve zaman sınırlarına çarpmaktadır. Matematiksel olarak ifade etmek gerekirse, N adet belge içeren bir veri seti için yapılması gereken toplam karşılaştırma (eşleşme sınaması) sayısı

$$\frac{N \cdot (N - 1)}{2}$$

formülü ile hesaplanmaktadır.

Bu durum, veri büyüklüğü ile işlem süresi arasında $O(N^2)$ (karesel) bir zaman karmaşıklığı yaratarak, problemi standart işlemci mimarilerinde hesaplamalı olarak yönetilemez hale getirmektedir.

Bu çalışmanın temel amacı, veri setinin tamamını satır satır taramak yerine, benzer olma ihtimali yüksek olan belgeleri (aday çiftleri) olasılıksal yöntemlerle hızlıca filtreleyen LSH (Locality-Sensitive Hashing) tabanlı bir mimari tasarlamak ve bu yaklaşımın hata payını (trade-off) kesin matematiksel metriklerle analiz etmektir. $O(N^2)$ zaman karmaşıklığının yarattığı darboğazı aşmak için MinHash algoritmaları entegre edilmiş ve yüksek boyutlu metin verisi, düşük boyutlu imza matrislerine (signature matrices) dönüştürülerek paralel işlemeye uygun ölçeklenebilir bir boru hattı (pipeline) kurulmuştur.

Bu temel motivasyonlar ışığında, bu çalışma aşağıdaki araştırma sorularına (Research Questions - RQ) matematiksel ve deneysel kanıtlarla yanıt aramaktadır:

- **RQ1:** Büyük hacimli haber metinlerinde koordineli içeriklerin tespiti için MinHash ve LSH mimarisinin kullanılması, evrensel tarama yapan kaba kuvvet (brute-force) yöntemine kıyasla işlem süresini ve hesaplama maliyetlerini ne ölçüde optimize etmektedir?
- **RQ2:** Olasılıksal bir yaklaşım olan LSH algoritması karesel zaman karmaşıklığı problemini çözerken, Kesin Gerçeklik (Ground Truth) baz alındığında modelin sınıflandırma yeteneği üzerinde (özellikle Duyarlılık ve F1-Skoru bağlamında) nasıl bir istatistiksel takas (trade-off) yaratmaktadır?

3. Literatür Taraması (Literature Review)

Büyük hacimli metin koleksiyonlarında tüm çiftlerin karşılaştırılmasına dayalı $O(N^2)$ brute-force yaklaşımlar, hem bellek hem de zaman açısından hızla ölçeklenemez hale gelmektedir. Bu nedenle, MinHash/LSH ve yaklaşık en yakın komşu (ANN) arama, doğruluk-maliyet ödünleşimini kontrol ederek pratik çözümler sunar. Aşağıdaki literatür, sunduğunuz boru hattını bu bağlamda konumlandırmak için kullanılabilir.

3.1. Büyük Veride Metin Benzerliği ve Brute-Force Sınırlamaları

YFCC100M gibi yüz milyon–milyar ölçekli veri kümelerinde en yakın komşu grafi kurarken tüm çiftlerin taranması, GPU ile optimize edilmiş brute-force dahi kullanılsa ciddi bir darboğaz oluşturur; Johnson vd. milyar vektör üzerinde brute-force, yaklaşık ve sıkıştırılmış aramayı hızlandırmak için GPU-optimizasyonlarına başvurmak zorunda kalmaktadır [1]. Benzer biçimde SimRank* çalışması, tüm düğüm çiftlerinin benzerliğini hesaplamının $O(N^2)$ bellek ve $O(k \cdot n \cdot m)$ zaman gerektirdiğini, bu nedenle kümeleme ve tek-kaynak algoritmalarla ölçeklenebilirliğin artırılması gerektiğini vurgular [2]. ANN arama üzerine kapsamlı karşılaştırma çalışmaları, yüksek boyutlu uzaylarda kesin aramanın pratik olmaması nedeniyle yaklaşık yöntemlere geçişi sistematik olarak ortaya koyar [3] [4].

3.2. MinHash ve LSH Teorisi: Jaccard ve Hız/Doğruluk Ödünleşimi

MinHash/LSH ailesi, Jaccard benzerliğini düşük boyutlu imzalar üzerinden tahmin ederek büyük veri ortamlarında benzerlik aramasını hızlandırır. Ertl, Jaccard ve olasılık Jaccard benzerliği için tek geçişli ProbMinHash algoritmaları tanımlayarak, geleneksel minwise hashing'e göre mertebeler düzeyinde hız kazanımı ve $O(n + m \log m)$ zaman karmaşıklığına işaret eder; imza uzunluğu ve algoritma varyantları üzerinden tahmin hatası/performans ödünleşimi ayrıntılı olarak analiz edilir [5]. Marçais vd. ise MinHash'in Jaccard'a duyarlılığını edit mesafesine genişleten Order MinHash (OMH) ile, imza boyutu hafifçe artarken dizilerin içerik ve sıra bilgisini birlikte yakalayabilen bir LSH formülasyonu sunar [6]. Çoklu metrikleri entegre eden M2LSH/M3Hash yaklaşımı, tek metrik LSH'nin karmaşık biyolojik dizilerdeki sınırlamalarını göstererek, daha iyi hizalama doğruluğu (daha düşük false discovery rate) karşılığında daha yüksek hesaplama maliyetinin kabul edildiği bir hız/doğruluk ödünleşimi sergiler [7]. PolyMinHash çalışması da, poligon benzerliğinde

MinHash imza uzunluğunu değiştirerek Recall@k ile çalışma süresi arasında, imza uzadıkça adayların sert filtrelandığı ve brute-force'a kıyasla %70–%98 oranında aday budama sağlandığı bir trade-off rapor eder [8]. Bu tüm sonuçlar, MinHash/LSH tabanlı boru hatlarının parametre ayarları üzerinden hassas biçimde ayarlanabilir hız–doğruluk eğrilerine sahip olduğunu göstermektedir [5] [6] [7] [8].

3.3. Haber ve Medya Verilerinde Koordineli/Kopya İçerik Tespiti

Haber akışlarında yakın kopya içerik, özellikle telifli ajans metinlerinin küçük varyantları ve yerelleştirilmiş sürümler nedeniyle yaygındır. Rodier ve Carter, Broder'in shingling algoritmasını çevrimiçi bir sisteme uyararak web haberleri üzerinde near-duplicate tespiti yapmış, F1-skoru yüksek ve gerçek zamanlı çalışabilen bir sistem sunmuş; metot, hassasiyet/duyarlılık değiş tokuşu için ayarlanabilir hale getirilmiştir [9]. Daha güncel bir çalışma, toplu ve ücretli (paywalled) haber beslemelerinde geliştirilmiş bir near-duplicate tespit yöntemi önerirken MinHash ve SimHash'i endüstriyel ölçekte kıyaslama amaçlı temel olarak kullanmakta; yüksek yüzeysel benzerlik içeren veri setlerinde MinHash/SimHash'in güçlü performans verdiğini, daha zor veri kümelerinde ise ek modelleme ihtiyacını göstermektedir [10]. Novo ve Gedikli'nin isim varlıklarına dayalı BERT modeli, iş enerjisi haberlerinde near-duplicate tespitte %97'nin üzerinde ölçüt değerlerine ulaşarak, gözetimli ve semantik odaklı yaklaşımların kalitesini ortaya koyar; ancak etiketleme gereksinimi ve haber dinamikliği nedeniyle üretim ortamlarında etiketli veri maliyetine dikkat çeker [10] [11]. Çok modlu sahte haber analizinde ise, metin-görüntü benzerliği ölçümleri üzerinden sahte haberlerin tipik olarak daha yüksek görsel-metinsel benzerlik gösterdiği bulunarak, benzerlik ölçümlerinin manipülatif içerik tespitinde temel özellikler olarak kullanılabileceği ortaya konur [12]. ScrutNet gibi derin topluluk modelleri de haber metninde sahte/gerçek sınıflandırmasında yüksek doğruluk (örneğin 4142/4160 doğru sınıflama) sağlamak üzere F1 vb. ölçütlerle değerlendirilmektedir [13].

3.4. Model Değerlendirmesi, Ground Truth ve Metrikler (Precision/Recall/F1)

Yaklaşık arama yapılarının kesin yöntemlere göre değerlendirilmesinde Precision, Recall ve F1-skoru standart hale gelmiştir. ANN arama üzerine geniş ölçekli karşılaştırma çalışmaları, birden çok veri kümesi ve sorgu iş yükünde çeşitli yöntemleri kesin en yakın komşu sonuçlarına karşı test ederek, farklı yapıların hız–doğruluk eğrilerini özellikle recall tabanlı ölçütler ve gecikme üzerinden raporlar [3]. HANNIS yaklaşımı, yüksek boyutlu görüntü özellikleri için tasarlanan hibrit bir ANN indeksine ilişkin deneylerinde, farklı derinliklerde recall, precision ve F1-skorunu hesaplayarak hem taranan aday sayısı hem de doğruluk açısından klasik yöntemleri aştığını göstermektedir [14]. Entity Resolution bağlamında grafik tabanlı ve bölütleme tabanlı ANN yapıları, bilinen ground truth'e sahip bir milyonluk veri kümelerinde precision, recall ve F1 üzerinden karşılaştırılarak belirli hatırlama hedeflerinde (örneğin yüksek doğruluk gerektiren senaryolar vs. yüksek throughput odaklı kullanım) hangi mimarinin uygun olduğuna dair uygulama-odaklı öneriler sunar [15]. PolyMinHash, brute-force arama ile elde edilmiş ground truth'e karşı Recall@k ve hız iyileştirmelerini rapor ederek, LSH tabanlı sistemin aday uzayı %70–%98 oranında budarken kabul edilebilir hatırlama seviyelerini koruduğunu gösterir [8]. ANN sistemlerinde sorgu bazlı uyarlanabilir

erken durdurma teknikleri, sabit yapılandırmalarla aynı doğruluk hedefine ulaşırken toplam arama işini azaltmayı hedefler; bu bağlamda doğruluk tipik olarak “ground truth en yakın komşunun bulunma oranı” ve ilgili ölçütlerle izlenir [4]. Diğer yandan, büyük ölçekli NLP sınıflayıcılarının değerlendirilmesinde klasik precision/recall/F1’nin güven skorlarına duyarsızlığı ele alınmış, bu nedenle olasılıksal uzantılar (cPrecision, cRecall, cF1) önerilerek, model güveninin sistem davranışına etkisini daha ayrıntılı izleyen metrikler tanımlanmıştır [16].

Sonuç olarak literatür, $O(N^2)$ brute-force benzerlik aramasının büyük metin/vektör koleksiyonları için pratik olmadığını; bunun yerine MinHash/LSH ve ANN yapılarının parametrelenebilir hız-doğruluk ödünleşimleri sunduğunu açık biçimde göstermektedir [1] [5] [6] [3] [8]. Haber ve sahte haber alanında, MinHash/SimHash gibi imza tabanlı yaklaşımlar ile BERT temelli semantik modellerin yakın kopya ve koordineli içerik tespitinde tamamlayıcı roller oynadığı görülmektedir [10] [9] [12] [11] [13]. Bu çalışmalarla uyumlu olarak, News Category Dataset v3 üzerinde kurduğunuz MinHash/LSH tabanlı boru hattının, brute-force ile elde edilen ground truth’e göre precision, recall ve F1-skorlarıyla değerlendirilmesi, güncel ANN ve metin benzerliği literatürünün metodolojik çizgisine doğrudan oturmaktadır [14] [15] [3] [8].

4. Methodology

Bu çalışmada, yüz binlerce belge içeren büyük boyutlu metin veri setlerinde koordineli ve kopya içeriklerin tespit edilmesi için dört ardışık aşamadan oluşan ölçeklenebilir bir veri boru hattı (data pipeline) tasarlanmıştır. Yöntem; ön işleme, boyut indirgeme, olasılıksal filtreleme ve kesin doğrulama adımlarını içermektedir.

4.1. Ön İşleme ve K-Gram (Shingle) Üretimi

Çalışmanın ilk aşamasında, haber metinleri doğal dil işleme standartlarına uygun olarak ön işlemden geçirilmiştir. Haber başlıkları ve kısa özetleri birleştirilmiş, tüm metinler küçük harfe dönüştürülmüş ve noktalama işaretlerinden arındırılarak sadece alfanümerik karakterler bırakılmıştır. Ardından, her bir belge D ardışık kelimelerden oluşan k uzunluğundaki alt kümeler (shingle) ayrılmıştır. Bu çalışmada kelime tabanlı $k = 3$ (trigram) modeli tercih edilmiştir. İki belge (A ve B) arasındaki örtüşme oranı, kümelerin kesişiminin birleşimine oranını ifade eden Jaccard Benzerliği ile tanımlanmıştır:

$$J(A, B) = \frac{|A \cap B|}{|A \cup B|}$$

4.2. MinHash ile İmza Matrisinin (Signature Matrix) Oluşturulması

K-gram kümelerinin doğrudan karşılaştırılması, büyük veri setlerinde belleğe sığmayan seyrek matrisler (sparse matrices) oluşturur. Bu bellek ve hesaplama sorununu çözmek için MinHash algoritması kullanılarak belgelerin boyutları indirgenmiştir. Algoritma, A ve B kümeleri üzerinden rastgele bir h hash fonksiyonu (veya permütasyon) geçirildiğinde, her iki

kümenin minimum hash değerlerinin birbirine eşit olma olasılığının doğrudan Jaccard benzerliğine eşit olduğu teorisine dayanır:

$$P(h_{min}(A) = h_{min}(B)) = J(A, B)$$

Bu özellik kullanılarak, her bir belge için 100 farklı rastgele hash permütasyonu uygulanmış ve orijinal belgelerin uzunluğundan bağımsız olarak her belgeyi temsil eden 100 boyutlu sabit bir "İmza Matrisi" (Signature Matrix) elde edilmiştir.

4.3. Yerel Duyarlı Hashing (LSH) ile Olasılıksal Filtreleme

MinHash imzalarının oluşturulması boyutu küçültse de, tüm belgelerin imzalarının birbiriyle karşılaştırılması işlemi hala $O(N^2)$ karmaşıklığına sahiptir. Bu çalışmada hesaplama sayısını dramatik şekilde düşürmek için Yerel Duyarlı Hashing (Locality-Sensitive Hashing - LSH) mimarisi kurulmuştur.

100 boyutlu imza matrisi, her biri r satır içeren b adet banda bölünmüştür ($b = 20, r = 5$). Bir bant içindeki tüm satırların hash değerleri aynı olan belgeler aynı "kovaya" (bucket) düşürülerek aday çift (candidate pair) olarak işaretlenmiştir. İki belgenin benzerliği s olduğunda, LSH mimarisinin bu iki belgeyi aday çift olarak seçme olasılığı matematiksel olarak şu fonksiyonla ifade edilir:

$$P(Aday) = 1 - (1 - s^r)^b$$

Sistemin hangi benzerlik oranından sonra belgeleri aday göstermeye başlayacağını belirleyen LSH Eşik Değeri (Threshold, t), bant ve satır sayısına bağlı olarak aşağıdaki formülle yaklaşık olarak belirlenmiştir:

$$t \approx \left(\frac{1}{b}\right)^{\frac{1}{r}}$$

Mimaride seçilen $b = 20$ ve $r = 5$ parametreleri için teorik eşik değeri yaklaşık olarak $t \approx 0.55$ civarında konumlandırılmış; böylece potansiyel kopyalar yüksek bir kapsayıcılıkla filtrelenmiştir.

4.4. Paralel Mimari ile Kesin Gerçeklik (Ground Truth) Analizi

Geliştirilen LSH mimarisinin sınıflandırma hatasını (False Positive ve False Negative) istatistiksel bir örneklem tahmini yerine **kesin matematiksel kanıtlarla** ölçmek amacıyla tam sayım (census) değerlendirmesi yapılmıştır. Toplam 209.527 belge içeren veri setinin kendi içindeki tüm olası eşleşme kombinasyonları şu denklemle hesaplanmıştır:

$$Toplam \text{ İşlem} = \frac{N \cdot (N - 1)}{2} \approx 21.95 \cdot 10^9$$


Yaklaşık 22 milyar belge çiftinin Jaccard benzerliğini hesaplayan $O(N^2)$ kaba kuvvet (brute-force) taraması, Python kütüphaneleri ve 12 mantıksal iş parçacığı (threads) tahsis edilen paralel bir işlem havuzu (multiprocessing pool) üzerinde çalıştırılmıştır. İşlemci termal darboğazlarını önlemek için optimize edilen bu kaba kuvvet algoritması, evrenin tamamını tarayarak LSH'in doğrulama metrikleri için referans alınacak "Kesin Gerçeklik" (Ground Truth) matrisini oluşturmuştur.

5. Result and Discussion

Bu çalışmada geliştirilen MinHash ve LSH tabanlı boru hattının sınıflandırma başarısı, 209.527 belgelik veri setinin tamamı üzerinden elde edilen Kesin Gerçeklik (Ground Truth) matrisi ile değerlendirilmiştir. Veri setindeki olası tüm eşleşme kombinasyonları (yaklaşık 21.95×10^9 işlem), 12 mantıksal iş parçacıklı paralel mimari kullanılarak kaba kuvvet (brute-force) yaklaşımıyla 3.23 saatte taranmıştır.

LSH algoritmasının tahminleri ile kaba kuvvet sonuçlarının karşılaştırılması sonucunda elde edilen Karmaşıklık Matrisi (Confusion Matrix) değerleri ve akademik performans metrikleri aşağıda sunulmuştur:

- **Doğru Pozitif (True Positive - TP):** 6.321
- **Yanlış Negatif (False Negative - FN):** 822
- **Yanlış Pozitif (False Positive - FP):** 1.383
- **Duyarlılık (Recall):** %88.49
- **Kesinlik (Precision):** %82.05
- **F1-Skoru (F1-Score):** %85.15



Resim 1. Confusion matrisi grafik görünümü.

5.1. Zaman Karmaşıklığı ve Başarım Takası (The Time-Accuracy Trade-off)

Sonuçlar incelendiğinde, LSH algoritmasının veri seti içerisine gizlenmiş olan gerçek kopya içeriklerin %88.49'unu (6.321 adet) başarıyla tespit ettiği görülmektedir. Geleneksel kaba kuvvet yöntemi bu tespiti yapabilmek için paralel donanım kullanımına rağmen saatler harcarken, LSH tabanlı olasılıksal yaklaşım aday çiftleri tespit etme sürecini saniyeler/dakikalar seviyesine indirmiştir. Kaçırılan 822 adet kopya belge (FN), $O(N^2)$ zaman karmaşıklığından kaçınmak ve hesaplama maliyetini düşürmek adına ödenen kabul edilebilir bir takas (trade-off) olarak değerlendirilmektedir.

5.2. Hata Analizi: Yanlış Negatifler (False Negatives)


LSH modelinin 822 belgeyi gerçekte kopya olmasına rağmen kaçırmasının temel nedeni, algoritmanın olasılıksal doğasıdır. Modelde belirlenen $b = 20$ ve $r = 5$ parametreleri belirli bir eşik değeri (threshold) yaratmaktadır. Jaccard benzerliği bu eşik değerinin çok az altında kalan veya MinHash permütasyonları sırasında şans eseri aynı bantlarda (bands) çakışma (hash collision) yaşayamayan belgeler, aday havuzuna girememiş ve sistem tarafından göz ardı edilmiştir.

5.3. Hata Analizi: Yanlış Pozitifler (False Positives)

Algoritmanın 1.383 belge çiftini hatalı bir şekilde "kopya" olarak işaretlemesinin (Kesinliğin %82.05 seviyesinde kalmasının) arkasında yatan temel faktör ise veri setinin yapısal karakteristiğidir. Özellikle kısa haber özetlerinde veya ajansların kullandığı standart kalıp cümlelerde (boilerplate text) 3-gram (shingle) kümelerinin örtüşme oranı suni olarak yüksek çıkabilmektedir. İki haberin anlamsal (semantik) olarak tamamen farklı konuları işlemesine rağmen, kullanılan jenerik kelime gruplarının yüksek kesişim göstermesi, sistemin Jaccard benzerliği sınırını aşmasına ve bu belgeleri hatalı bir şekilde koordineli içerik olarak etiketlemesine neden olmuştur.

5.4. Genel Değerlendirme

Algoritmanın hatalı kabulleri ve kaçırdığı içerikler birlikte değerlendirildiğinde, Kesinlik ve Duyarlılık metriklerinin harmonik ortalaması olan F1-Skoru %85.15 olarak ölçülmüştür. Bu yüksek oran, herhangi bir ağır derin öğrenme (Deep Learning) modeli veya etiketli veri kullanılmaksızın, salt matematiksel boyut indirgeme yöntemleriyle devasa haber koleksiyonlarında kopya içeriklerin son derece yüksek bir doğrulukla filtrelenebileceğini kanıtlamaktadır.



Resim 2. Sınıflandırma başarılarını gösteren grafik.

6. Limitations

Geliştirilen boru hattının (pipeline) bazı yapısal ve donanımsal kısıtları bulunmaktadır:

- **Shingle Boyutu (k-gram) Bağımlılığı:** $K=3$ olarak seçilen shingle boyutu, kısa metinlerde (tweet veya özet haberler) çok az sayıda token ürettiği için bu tarz belgelerde Jaccard eşiğinin gereksiz yere aşılmasına (False Positive) neden olabilmektedir.
- **Eşik Değeri Hassasiyeti:** LSH bant ve satır sayıları (b ve r) ile belirlenen 유사lık eşiği (threshold), statiktir. Belirli haber kategorilerinde eşiğin %80'in altında olması gerekebilirken, sistem tüm kategori tiplerine tek bir eşik uygulamıştır.
- **Donanım Sınırları:** Değerlendirme aşamasındaki tam kaba kuvvet testi, standart donanımlarda bellek (OOM) ve termal darboğazlara yol açma riski barındırdığından, gelecekteki çok daha büyük veri setlerinde (örneğin milyonlarca belge) bu doğrulama işleminin Apache Spark gibi dağıtık mimarilerde veya GPU (CUDA) tabanlı seyrek matrislerle yapılması zorunludur.

7. Conclusion

Bu çalışmada, klasik bilgi geri kazanımı yöntemlerinin tıkanıdığı yüz binlerce belgelik bir veri setinde kopya içeriklerin tespiti problemi, MinHash ve LSH mimarisi ile başarıyla çözülmüştür. Büyük hacimli metin madenciliği uygulamalarında karşılaşılan $O(N^2)$ zaman

karmaşıklığı problemi, LSH'in sunduğu olasılıksal aday belirleme filtreleriyle aşılmış ve işlem süreleri pratik kullanılabilir seviyelere indirilmiştir.

Sistemin başarımını istatistiksel tahminler yerine evrensel doğrulukla kanıtlamak amacıyla, 209.527 belgenin birbirleriyle olan yaklaşık 21.9 milyar eşleşme kombinasyonu 12 mantıksal iş parçacıklı kaba kuvvet taramasından geçirilmiştir. Değerlendirme sonucunda modelin, gizli kopya içeriklerin %88.49'unu (Duyarlılık) başarıyla yakaladığı görülmüştür. Elde edilen %85.15'lik F1-Skoru, algoritmanın olasılıksal doğasına rağmen kesin gerçekliğe (ground truth) oldukça yakın sonuçlar ürettiğini kanıtlamaktadır.

İşlemci çekirdeklerinin paralel kullanımıyla elde edilen Kesin Gerçeklik Matrisi, sistemin literatüre şeffaf bir değerlendirme metodu sunmasını sağlamıştır. Elde edilen bulgular doğrultusunda LSH algoritması; doğal dil işleme tabanlı öneri sistemlerinde, intihal tespit yazılımlarında ve haber doğrulama (fact-checking) platformlarında ölçeklenebilir ve güvenilir bir çözüm olarak konumlanmaktadır. Ölçeklenebilirlik, bellek optimizasyonu ve hız parametreleri göz önüne alındığında, bu mimari endüstriyel standartlardaki büyük veri problemleri için güçlü bir zemin hazırlamaktadır.

8. Kaynakça

1. Johnson J, Douze M, Jégou H. Billion-Scale Similarity Search with GPUs. *IEEE Transactions on Big Data*. 2017;7:535-547. doi:10.1109/tbdata.2019.2921572
2. Yu W, Lin X, Zhang W, Pei J, Mccann J. SimRank*: effective and scalable pairwise similarity search based on graph topology. *The VLDB Journal*. 2019;28:401 - 426. doi:10.1007/s00778-018-0536-3
3. Li W, Zhang Y, Sun Y, et al. Approximate Nearest Neighbor Search on High Dimensional Data — Experiments, Analyses, and Improvement. *IEEE Transactions on Knowledge and Data Engineering*. 2020;32:1475-1488. doi:10.1109/tkde.2019.2909204
4. Li C, Zhang M, Andersen D, He Y. Improving Approximate Nearest Neighbor Search through Learned Adaptive Early Termination. *Proceedings of the 2020 ACM SIGMOD International Conference on Management of Data*. 2020. doi:10.1145/3318464.3380600
5. Ertl O. ProbMinHash — A Class of Locality-Sensitive Hash Algorithms for the (Probability) Jaccard Similarity. *IEEE Transactions on Knowledge and Data Engineering*. 2019;34:3491-3506. doi:10.1109/tkde.2020.3021176
6. Marçais G, Deblasio D, Pandey P, Kingsford C. Locality-sensitive hashing for the edit distance. *Bioinformatics*. 2019;35:i127 - i135. doi:10.1093/bioinformatics/btz354
7. Nikaein H, Sharifi-Zarchi A. Multi-metric locality sensitive hashing enhances alignment accuracy of bisulfite sequencing reads: BisHash. *Bioinformatics Advances*. 2025;5. doi:10.1093/bioadv/vbaf144
8. Subedi A, Pokharel S, Puri S. PolyMinHash: Efficient Area-Based MinHashing of Polygons for Approximate Nearest Neighbor Search. *Proceedings of the 33rd ACM International Conference on Advances in Geographic Information Systems*. 2025. doi:10.1145/3748636.3762767
9. Rodier S, Carter D. Online Near-Duplicate Detection of News Articles. 2020.
10. Tumre S, Patil S, Kumar A. Improved Near-Duplicate Detection for Aggregated and Paywalled News-Feeds. 2025. doi:10.18653/v1/2025.naacl-industry.73
11. Novo AS, Gedikli F. Explaining BERT model decisions for near-duplicate news article detection based on named entity recognition. *2023 IEEE 17th International Conference on Semantic Computing (ICSC)*. 2023. doi:10.1109/icsc56153.2023.00054
12. Zhang X, Dadkhah S, Weismann AG, Kanaani MA, Ghorbani A. Multimodal Fake News Analysis Based on Image–Text Similarity. *IEEE Transactions on Computational Social Systems*. 2024;11:959-972. doi:10.1109/tcss.2023.3244068
13. Verma A, Priyanka P, Khan T, et al. ScrutNet: a deep ensemble network for detecting fake news in online text. *Social Network Analysis and Mining*. 2025;15. doi:10.1007/s13278-025-01412-3

14. Rahman MM, Tešić J. Evaluating Hybrid Approximate Nearest Neighbor Indexing and Search (HANNIS) for High-dimensional Image Feature Search. *2022 IEEE International Conference on Big Data (Big Data)*. 2022. doi:10.1109/bigdata55660.2022.10021048
15. Karapiperis D, Akritidis L, Bozanis P, Verykios V. A comparative analysis of graph-based and partition-based approximate nearest neighbor search for large-scale entity resolution. *Intelligent Decision Technologies*. 2025;19:3826 - 3840. doi:10.1177/18724981251388888
16. Yacouby R, Axman D. Probabilistic Extension of Precision, Recall, and F1 Score for More Thorough Evaluation of Classification Models. 2020. doi:10.18653/v1/2020.eval4nlp-1.9

EKLER

Github Linki: <https://github.com/berkantkozan/BigDataClass>

Veri Seti Linki: <https://www.kaggle.com/datasets/rmisra/news-category-dataset?resource=download>