

BM531 BÜYÜK VERİ ANALİTİĞİ ÖDEV III



BERKANT KOZAN

25832901024

GAZİ ÜNİVERSİTESİ
FEN BİLİMLERİ ENSTİTÜSÜ

Konuya Duyarlı (Topic-Sensitive) PageRank: Gelişmiş Uygulamalar, Doğruluk İyileştirmeleri ve Sınırlar

ÖZET

Web üzerindeki bilgi hacminin kontrol edilemez boyutlara ulaşması, bilgi getirimi ve arama algoritmalarının önemini artırmıştır. Geleneksel PageRank algoritması bağlantı yapılarına dayanarak küresel (global) bir önem skoru atarken, bu yaklaşım kullanıcının arama bağlamını göz ardı etmektedir. Bu çalışmada, bağlama duyarlı bir algoritma olan Konuya Duyarlı PageRank (Topic-Sensitive PageRank - TSPR) incelenmektedir. Sağlanan kaynaklar doğrultusunda TSPR'nin matematiksel altyapısı [6], hipermetin bağlantılarının yanı sıra içerik benzerliğini (Kosinüs, Jaccard, Sık Geçen Terim Kümeleri) kullanan optimizasyonları [2, 3], kişiselleştirilmiş sıralamanın sınırları [4] ve otomatik metin özetleme gibi arama motorları dışındaki yapısal olmayan veri setlerine uygulanabilirliği [1, 5] değerlendirilmiştir.

1. GİRİŞ

Arama motorları, çok büyük veri yığınları içinden kullanıcının niyetine uygun sonuçları getirmek zorundadır. Klasik PageRank algoritması, web sayfalarının otoritesini, ağır bağlantı yapısı üzerinden değerlendirerek tüm sayfalara statik ve küresel bir önem derecesi atar. Ancak bu "tek beden herkese uyar" mantığı, kullanıcının belirli bir konudaki aramalarında bağlamı yakalamakta yetersiz kalabilir. Bu ihtiyacı karşılamak üzere, Taher Haveliwala tarafından "Konuya Duyarlı PageRank" (TSPR) algoritması önerilmiştir [6]. TSPR, sayfaların önemini tek bir metrik üzerinden değil, farklı konular bağlamında birden fazla PageRank vektörü hesaplayarak belirlemeyi amaçlar.

Son yıllarda bu algoritmaların sınırlarını aşmak için makine öğrenmesi ve zamansal (temporal) analiz teknikleri geliştirilmektedir. Güncel yaklaşımlar, TSPR modellerini zaman kısıtlı çerçevelere oturtarak (örneğin TPPR), büyük ölçekli ve dinamik ağlardaki otorite dağılımını çok daha yüksek doğrulukla ve düşük hata paylarıyla tahmin edebilmektedir [7].

2. TEMEL KONUYA DUYARLI PAGERANK MODELİ

Haveliwala (2003), TSPR'nin arama sorgularının bağlamını anlamada nasıl kullanıldığını ortaya koymuştur [6]. Çevrimdışı işlem (offline) aşamasında, Open Directory Project (ODP) gibi kaynaklardaki en üst düzey kategorilere göre (örneğin sağlık, sanat, teknoloji) ağırlıklandırılmış 16 farklı PageRank vektörü hesaplanır. Arama anında (query-time) ise, kullanıcının sorgusu veya arama yaptığı sayfanın bağlamı ile bu temel konular arasındaki benzerlik hesaplanır. Sayfaların nihai sorgu

bazlı önem skoru, hesaplanan bu vektörlerin doğrusal birleşimi ile elde edilir. Bu sayede, "blues" gibi birden fazla anlama gelebilen (müzik türü veya psikolojik depresyon) kelimeler, kullanıcının o anki arama bağlamına göre çok daha doğru bir şekilde sınıflandırılır ve sıralanır [6].

Geleneksel PageRank algoritması, her sayfanın eşit derecede önemli olduğu varsayımıyla, rastgele sörfçünün herhangi bir sayfaya atlama olasılığını uniform (tekdüze) bir vektör ile modeller. Geleneksel PageRank formülasyonu şu şekildedir:

$$PR = \alpha M \cdot PR + (1 - \alpha)e$$

Burada M geçiş olasılık matrisini, α sönümlleme faktörünü (genellikle 0.85) ve e ise tüm elemanları $1/N$ olan (N : toplam sayfa sayısı) vektörü temsil eder.

Konuya Duyarlı PageRank (TSPR) ise bu "tekdüze atlama" varsayımını yıkar. Haveliwala'nın modelinde, j konusu için hesaplanan PageRank vektörü (PR_j), kullanıcıyı rastgele bir sayfaya değil, o konuyla ilgili güvenilir çekirdek (seed) sayfalara yönlendiren bias/teleportasyon vektörü (v_j) ile hesaplanır:

$$PR_j = \alpha M \cdot PR_j + (1 - \alpha)v_j$$

Vektör v_j içindeki bir i sayfasının değeri, eğer i sayfası j konusuna ait temel kümeye (T_j) dahilse $1/T_j$ değilse 0 olarak tanımlanır. Bu ufak modifikasyon, tüm grafin o konunun perspektifinden yeniden ağırlıklandırılmasını sağlar.

3. TSPR'NİN ETKİNLİĞİ, SINIRLARI VE KİŞİSELLEŞTİRMENİN FAYDASI

Kişiselleştirilmiş ve konuya duyarlı PageRank algoritmalarının gerçekte ne ölçüde fayda sağladığı Al-Saffar ve Heileman (2007) tarafından deneysel olarak test edilmiştir [4]. Yaklaşık 300.000 sayfalık bir web taraması üzerinde yapılan çalışmada, kişiselleştirilmiş sıralamalar ile genel PageRank sonuçları arasındaki örtüşme (overlap) oranları ölçülmüştür. Sonuçlara göre, arama motorlarının yaygın olarak kullandığı sönümlleme faktörü (damping factor) $\alpha=0.85$ olduğunda, tam kişiselleştirilmiş sonuçların %40'ı genel PageRank sonuçlarıyla birebir aynı sayfaları döndürmüştür. Konuya duyarlı (topic-sensitive) sonuçların ise ilk 1000 sonuç için %70 oranında genel PageRank sonuçlarıyla örtüştüğü görülmüştür [4]. Bu çalışma, TSPR'nin kullanıcıya "tamamen yeni ve farklı sayfalar" keşfettirme yeteneğinin sınırlı olduğunu; hesaplama maliyetlerinin getirdiği avantajın her senaryoda optimum olmayabileceğini vurgulamaktadır.

4. İÇERİK BENZERLİĞİ KULLANARAK TSPR DOĞRULUĞUNUN ARTIRILMASI

Geleneksel TSPR salt bağlantı yapısına dayandığı için manipülatif bağlantı spamlerine (link farm/spam) karşı hassas olabilir. Bu sorunu çözmek için Rezvani ve Hashemi (2012), rastgele sörfçü (random surfer) modelini sayfa içeriklerinin benzerliğine göre hareket edecek şekilde modifiye etmiştir [3]. Jaccard indeksi ve Kosinüs (Cosine) benzerliği kullanılarak, sörfçünün bir sayfadan çıkış yaparken mevcut sayfaya daha

benzer içerikli sayfalara veya kendi konusu içindeki sayfalara geçiş olasılığı (geçiş ağırlığı) artırılmıştır. Bu entegrasyon, Naive-Bayes ve Maximum Entropy sınıflandırıcıları ile test edilmiş ve sıralama algoritmalarının doğruluğunu belirgin şekilde iyileştirmiştir [3].

Benzer bir hedefe yönelik olarak Yen ve Hsu (2009) "İlişkili Pagerank" (Associated Pagerank) algoritmasını önermiştir [2]. Bu yöntemde, belgeler arası anlamsal mesafe ve dışa dönük bağlantıların içeriksel benzerlikleri "sık geçen terim kümeleri" (frequent term sets) aracılığıyla hesaplanmaktadır. Pagerank değeri, ilgili sayfanın tüm dış bağlantılarına eşit dağıtılmak yerine, içerik olarak daha çok eşleşen (benzerlik oranı yüksek) sayfalara daha yüksek ağırlıklarla aktarılır. Bu yaklaşım, spam bağlantıların saptırıcı etkisini önlerken algoritmanın karmaşıklığını düşürmekte ve geleneksel TSPR'ye göre daha hızlı yakınsama (convergence) sağlamaktadır [2].


TSPR doğruluğunu artırmak için belgeler arası Kosinüs (Cosine) veya Jaccard benzerliklerinin kullanılması teorikte etkili olsa da, büyük veri konseptinde ciddi bir zaman karmaşıklığı engeline takılır. Milyonlarca düğümden oluşan bir web grafında tüm belge çiftlerinin benzerliğini hesaplamak $O(N^2)$ karmaşıklığı yaratır ve bu işlem devasa sistemlerde bile pratik değildir.

Bu hesaplama dar boğazını aşmak için büyük ölçekli mimarilerde **MinHash** algoritmaları ve Locality-Sensitive Hashing (LSH) gibi Yaklaşık En Yakın Komşu (ANN) teknikleri kullanılır. Binlerce kayıtlık bir benzerlik arama senaryosunda MinHash, belgeleri daha düşük boyutlu imzalar (signatures) halinde özetleyerek kosinüs benzerliği hesaplamalarının $O(N)$ süresine yaklaşmasını sağlar. Bu sayede Spark veya Hadoop kümelerinde çalışan paralel benzerlik algoritmaları, bellek taşmalarına (Out-Of-Memory) yol açmadan geçiş olasılıklarını (transition probabilities) dinamik olarak güncelleyebilir.

4.1. Zamana Dayalı Graflar ve TPPR Entegrasyonu

Geleneksel TSPR yaklaşımları, graf yapısının zamanla değişmediğini varsayar; ancak modern bilgi etkileşimleri saniyeler içinde evrimlenmektedir. Liao ve ark. (2024), bu sorunu aşmak için Zaman Kısıtlı Kişiselleştirilmiş PageRank (TPPR) matris faktörizasyonunu önermiştir [7]. Bu yöntem, düğüm benzerliklerini hesaplarken sadece bağlantı yapısını değil, bu bağlantıların kurulma zamanını da kısıt faktörü olarak ekler. Bu sayede, TSPR'nin ürettiği konu vektörleri, ağırlıklı güncel topolojik bilgilerini çok daha yüksek doğrulukla yakalar ve büyük ölçekli dinamik graflarda "incomplete similarity descriptions" (eksik benzerlik tanımları) sorununu minimize eder [7].

ZAMAN-DAYALI GRAFLAR VE TPPR ENTEGRASYONU



Resim 4.1. Zamana dayalı graphlarda PageRank. (Yapay Zeka Araçları ile oluşturulmuştur.)

Resim 4.1'de gösterilen Zamana Dayalı Graf (TPPR) senaryosu incelendiğinde, zaman faktörünün sayfa otoritesini nasıl değiştirdiği açıkça görülmektedir. Zaman T1'de "S" tohum düğümünden "B" düğümüne geçiş ağırlığı 0.19 iken, Zaman T2'de ağırlık 0.10'a düşmüştür. Klasik TSPR bu değişimi algılayamazken, TPPR modeli $G(t-1)$ geçmiş durumunu $G(t)$ güncel durumuyla sentezleyerek (Örn: C düğümünün Zaman T3'te yaprak düğümünden çıkararak otoritesini D'ye aktarması) konuya duyarlı vektörleri saniyeler içinde dinamik olarak yeniler.

5. TSPR'NİN FARKLI DİSİPLİNLERE UYARLANMASI

TSPR mantığı, bağlantıların (linklerin) açıkça bulunmadığı farklı yapılar için de kullanılabilir:

- 1) *Genel Belgelerde Sıralama*: Hatakenaka ve Miura (2012), web bağlantıları içermeyen genel metin belgeleri üzerinde "Konu Odaklı PageRank" (Topic-Driven PageRank - TDPR) yöntemini tanıtmıştır [5]. Belgeler arasında tf-idf ve kosinüs benzerliğiyle sanal bağlantılar kuran bu algoritma, konu kayması (topic-drift) sorununun önüne geçerek şüpheli belgeleri filtrelemiş ve belgeleri sorguya uygun biçimde sıralamayı başarmıştır [5].
- 2) *Otomatik Metin Özetleme*: Chongsuntornsri ve Sornil (2006), Tayca metinlerin özetini otomatik olarak çıkarmak için TSPR'yi kullanmıştır [1]. Bu çalışmada, bir metindeki cümleler veya kelime bölümleri grafın düğümleri (nodes) olarak tanımlanmış, bu bölümler arası benzerlik skorları ise kenar (edge) ağırlığı olarak belirlenmiştir. Belgenin başlığını "özel konu/bağlam" olarak kabul eden TSPR algoritması, başlıkla ve kendi içindeki önemli özelliklerle (lokasyon, TF-ISF vb.) ilişkili cümlelere daha fazla önem skoru atamıştır. Bu yöntem, Hopfield Ağları ve

Random Walk with Restart gibi diğer grafik algoritmalarından çok daha yüksek ROUGE ve F1 başarı skorları elde etmiştir [1].

6. BÜYÜK VERİ MİMARİLERİNDE TSPR'NİN DAĞITIK HESAPLANMASI

TSPR algoritması, teorik bağlamda oldukça başarılı olsa da, milyonlarca düğüm (node) ve milyarlarca kenardan (edge) oluşan güncel web graflarında tek bir makinenin bellek (RAM) ve işlemci kapasitesiyle hesaplanamaz. Bu noktada algoritmanın büyük veri ekosistemlerine entegre edilmesi zorunludur. Geleneksel olarak bu devasa matris çarpımları, Apache Hadoop altyapısındaki **MapReduce** kullanılarak çözülmüştür. Bu yöntemde, graf verisi parçalara ayrılarak kümedeki (cluster) farklı sunuculara dağıtılır ve her bir düğümün PageRank değeri iteratif "Map" (dağıtma) ve "Reduce" (toplama) aşamalarıyla hesaplanır. Ancak günümüzde, disk okuma/yazma (I/O) darboğazlarını aşmak için bellekçi (in-memory) veri işleme yeteneğine sahip **Apache Spark** ve onun graf işleme kütüphanesi olan **GraphX** tercih edilmektedir [8]. Büyük veri ekosistemlerinde TSPR hesaplamaları, milyarlarca kenarın (edge) sunucular arasında gidip gelmesi nedeniyle ciddi bir ağ iletişim (network shuffle) darboğazı yaratır. Apache Spark'ın GraphX kütüphanesi, bu sorunu aşmak için Vertex-Cut (düğüm kesme) yaklaşımını ve EdgePartition2D gibi stratejileri uygular.

GraphX üzerindeki Pregel API, TSPR hesaplamasını mesajlaşma (message-passing) mimarisine dönüştürür. Her iterasyonda bir düğüm (sayfa), sahip olduğu güncel TSPR skorunu dışa dönük bağlantılarına (out-edges) bir mesaj olarak gönderir ve gelen mesajları toplayarak (reduce) yeni skorunu hesaplar. Konuya özel 16 farklı temel vektörün hesaplanması, veri hafızada (in-memory) tutulduğu için geleneksel MapReduce disk okuma/yazma (I/O) maliyetlerine takılmadan hızlıca paralelleştirilir.

7. SONUÇ

TSPR, web üzerinde bilgi arama eylemine "kullanıcı ve arama bağlamını" dahil eden temel bir yaklaşımdır [6]. İlerleyen yıllarda içerik benzerliği metrikleriyle (Jaccard, Cosine) birleştirilerek ve terim analiziyle desteklenerek bağlantı spamlerine karşı daha dirençli hale getirilmiştir [2, 3]. Arama motorları dışında metin özetleme [1] ve genel evrak sıralama [5] gibi yapısal olmayan ağlarda da başarıyla uygulansa da, genel PR ile gösterdiği yüksek örtüşme oranları [4], bu yöndeki kişiselleştirme yatırımlarının maliyet-fayda ekseninde dikkatlice incelenmesi gerektiğini ortaya koymaktadır.

KAYNAKÇA

- [1] Chongsuntornsri, A., & Sornil, O. (2006). An Automatic Thai Text Summarization Using Topic Sensitive PageRank.
- [2] Yen, C. C., & Hsu, J. S. (2009). Associated Pagerank: Improved Pagerank Measured by Frequent Term Sets.
- [3] Rezvani, M., & Hashemi, S. M. (2012). Enhancing Accuracy of Topic Sensitive PageRank Using Jaccard Index and Cosine Similarity.
- [4] Al-Saffar, S., & Heileman, G. (2007). Experimental Bounds on the Usefulness of Personalized and Topic-Sensitive PageRank.
- [5] Hatakenaka, S., & Miura, T. (2012). Query and Topic Sensitive PageRank for General Documents.
- [6] Haveliwala, T. H. (2003). Topic-Sensitive PageRank: A Context-Sensitive Ranking Algorithm for Web Search.
- [7] Liao, Z., Liu, T., He, Y., & Lin, L. (2024). Effective Temporal Graph Learning via Personalized PageRank. *Entropy*, 26(7), 588.
- [8] Xin, R. S., Gonzalez, J. E., Franklin, M. J., & Stoica, I. (2013). GraphX: A resilient distributed graph system on Spark. *First International Workshop on Graph Data Management Experiences and Systems (GRADES)*.