

BM531 BÜYÜK VERİ ANALİTİĞİ ÖDEV IV



BERKANT KOZAN

25832901024

**GAZİ ÜNİVERSİTESİ
FEN BİLİMLERİ ENSTİTÜSÜ**

Kavram Kayması Altında Uyarlanabilir Veri Akışı Kümeleme: Bellek Kısıtlı Optimizasyon Yaklaşımları

Özet

Veri akışı madenciliği, sınırsız veri hacmi ve sürekli değişen veri karakteristiği nedeniyle geleneksel veri madenciliği yöntemlerinden ayrılmaktadır. Bu çalışmada, verinin istatistiksel özelliklerinin zamanla değişmesi olarak tanımlanan kavram kayması (concept drift) olgusu altında, kısıtlı bellek kaynakları ile gerçekleştirilen uyarlanabilir kümeleme stratejileri incelenmiştir. Özellikle mikro-kümeleme, sönmüleme fonksiyonları ve çekirdek kümeler (coresets) gibi optimizasyon tekniklerinin SCI/SCIE kapsamındaki güncel literatürdeki karşılıkları analiz edilmiştir. Araştırma sonucunda, bellek verimliliği ile model doğruluğu arasındaki ödünleşimin (trade-off) yönetilmesinde kullanılan hibrit yaklaşımların önemi vurgulanmaktadır.

1. Giriş

Günümüzde nesnelerin interneti (IoT), borsa verileri ve sosyal medya akışları gibi kaynaklar, verinin saniyede binlerce nokta hızında üretildiği "veri akışları" (data streams) oluşturmaktadır. Bu ortamlarda iki temel kısıt mevcuttur: **Bellek kısıtı** (verinin tamamının saklanamaması) ve **zaman kısıtı** (her verinin yalnızca bir kez ve hızlıca işlenebilmesi).

Veri akışı kümeleme problemlerinde en büyük engel "Kavram Kayması"dır. Kavram kayması, verinin altındaki veri üretim mekanizmasının (data distribution) zamanla değişmesidir. Bu durum, sabit modellerin zamanla geçerliliğini yitirmesine yol açar [1]. Bellek kısıtlı optimizasyon yaklaşımları, bir yandan eski ve geçerliliğini yitirmiş bilgiyi bellekten temizlemeyi, diğer yandan yeni ortaya çıkan kümeleri (clusters) kısıtlı donanım kaynaklarıyla tespit etmeyi amaçlar. Bu raporun amacı, bu dinamik süreci yöneten algoritmik temelleri ve akademik literatürdeki en başarılı optimizasyon modellerini sistematik bir şekilde sunmaktır.

2. Kavram Kayması ve Matematiksel Modellenmesi

Kavram kayması, giriş verisi X ile bu verinin ait olduğu küme yapıları (veya sınıflar) arasındaki ilişkinin zamanla evrilmesidir. t zamanındaki bir veri akışı için olasılık yoğunluk fonksiyonu $f_t(x)$ ise;

Ani Kayma (Abrupt Drift): $f_t(x)$ 'in bir anda tamamen değişmesi.

Kademeli Kayma (Gradual Drift): Eski ve yeni dağılımın bir süre bir arada bulunması.

Artımlı Kayma (Incremental Drift): Değişimin fark edilemeyecek kadar küçük adımlarla sürekli gerçekleşmesi [2].

Bellek kısıtlı bir sistemde, bu kaymaları tespit etmek için istatistiksel testler (örn. Page-Hinkley, ADWIN) kullanılır. Ancak bu testlerin kendisi de bir bellek maliyeti doğurur.

3. Bellek Kısıtlı Optimizasyon Stratejileri

Veri akışı kümeleme genellikle iki aşamalı (Two-phase) bir mimari ile çözülür: Çevrimiçi (Online) mikro-kümeleme ve Çevrimdışı (Offline) makro-kümeleme.

3.1. Mikro-Kümeleme ve İstatistiki Özetleme (Summarization)

Bellek verimliliği sağlamak için ham veri noktaları yerine Clustering Feature (CF) vektörleri saklanır. Bir mikro-küme C için özet bilgi şu şekilde formüle edilir:

$$CF = (n, \sum_{i=1}^n x_i, \sum_{i=1}^n x_i^2, \sum_{i=1}^n t_i)$$

Burada n nokta sayısını, x_i veri değerlerini ve t_i zaman damgalarını temsil eder. Bu yapı, verinin bellekte kapladığı alanı $O(N)$ 'den $O(K)$ 'ya (K : mikro-küme sayısı) indirger [3].

3.2. Sönümlleme Fonksiyonları ve Unutma Mekanizmaları

Eski verilerin model üzerindeki etkisini azaltmak ve belleği güncel veriye odaklamak için Zaman-Ağırlıklı (Time-Weighted) modeller kullanılır. Sönümlleme faktörü $\lambda > 0$ olmak üzere, bir mikro-kümenin ağırlığı şu şekilde güncellenir:

$$W(t) = W(t_{old}) \cdot 2^{\lambda \cdot (t - t_{old})} + 1$$

Bu mekanizma, "bellek temizliği" (pruning) süreçlerinde düşük ağırlıklı kümelerin silinerek kaynakların serbest bırakılmasını sağlar [4].

3.3. Çekirdek Kümeler (Coresets) Yaklaşımı

Coreset, büyük bir veri kümesini temsil eden ve üzerinde yapılan kümeleme işleminin orijinal veriyle neredeyse aynı sonucu verdiği çok küçük bir ağırlıklı alt kümedir. Bellek kısıtlı cihazlarda, veri akışı küçük parçalara (batch) bölünür, her parça için bir coreset oluşturulur ve bu coreset'ler bir ağaç yapısında (Merge-and-Reduce) birleştirilir. Bu yöntem, bellek kullanımını logaritmik seviyede tutar [5].

4. Literatürdeki Modern Algoritmalar ve Karşılaştırmalı Analiz

Aşağıdaki tablo, değerlendirilen temel algoritmaların bellek ve adaptasyon yaklaşımlarını özetlemektedir:

Algoritma	Kayma Yönetimi	Bellek Optimizasyonu	Avantaj / Dezavantaj
CluStream [3]	Pyramidal Time Window	Mikro-kümeleme	Tarihsel analizde güçlü / Yavaş adaptasyon
DenStream [4]	Fading Function	Outlier Micro-clusters	Gürültüye dayanıklı / Parametre hassasiyeti
StreamKM++ [5]	Coresets	Merge-and-Reduce Tree	Teorik garanti / Küme sayısı önceden bilinmeli
SAM-kNN [6]	Dual Memory (ST/LT)	K-NN tabanlı temizlik	Karmaşık kaymalarda başarılı / Yüksek CPU yükü
D-Stream [7]	Density Fading	Grid-based partitioning	Hızlı işlem / Boyut laneti (Curse of dimensionality)

Tablo 1. Değerlendirilen algoritmaların bellek ve adaptasyon yaklaşımları.

5. İleri Seviye Optimizasyon: Evrimsel ve Hibrit Yaklaşımlar

Son dönemdeki çalışmalar, kümeleme parametrelerinin (örn. mikro-küme yarıçapı veya sönümleme hızı) optimizasyonu için evrimsel algoritmaların kullanımına odaklanmıştır. Dinamik Diferansiyel Gelişim (Dynamic Differential Evolution) algoritmaları, kavram kayması algılandığında küme merkezlerini yeniden optimize etmek için kısıtlı bellek bütçesi içinde arama yapar [8].

Ayrıca, Federated Learning ekosisteminde, yerel cihazlardaki (Edge) bellek kısıtları nedeniyle kümeleme özetlerinin (prototiplerin) sunucuya gönderilerek global bir model oluşturulması, veri gizliliği ve bant genişliği optimizasyonu açısından literatürde yükselen bir trenddir [9].

6. Sonuç

Kavram kayması altında veri akışı kümeleme, durağan olmayan ortamlarda bilginin sürekliliğini sağlama sanatıdır. Bellek kısıtlı optimizasyonun geleceği, Coreset teorisinin derin öğrenme tabanlı temsil öğrenme (representation learning) ile birleştirilmesinde yatmaktadır. Özellikle yüksek boyutlu verilerde (metin, görüntü), veriyi doğrudan kümelemek yerine, belleği verimli kullanan düşük boyutlu projeksiyonlar üzerinde uyarlanabilir algoritmalar çalıştırmak kritik bir araştırma alanıdır [10].

Kaynakça

- [1] Gama, João & Aguilar-Ruiz, Jesús & Klinkenberg, Ralf. (2008). Knowledge discovery from data streams. *Intell. Data Anal.*. 12. 251-252. 10.3233/IDA-2008-12301.
- [2] Webb, Geoffrey & Hyde, Roy & Nguyen, Hai-Long & Petitjean, François. (2016). Characterizing Concept Drift. *Data Mining and Knowledge Discovery*. 30. 10.1007/s10618-015-0448-4.
- [3] Aggarwal, Charu & Han, Jiawei & Wang, Jianyong & Yu, Philip & Watson, T. & Ctr, Resch. (2003). A Framework for Clustering Evolving Data Streams.
- [4] Cao, Feng & Ester, Martin & Qian, Weining & Zhou, Aoying. (2006). Density-Based Clustering over an Evolving Data Stream with Noise. 2006. 10.1137/1.9781611972764.29.
- [5] Ackermann, M.R., Mörtens, M., Raupach, C., Swierkot, K., Lammersen, C., Sohler, C.: Streamkm++: a clustering algorithm for data streams. *J. Exp. Algorithmics (JEA)* **17**, 2–4 (2012)
- [6] Losing, Viktor & Hammer, Barbara & Wersing, Heiko. (2016). KNN Classifier with Self Adjusting Memory for Heterogeneous Concept Drift. 10.1109/ICDM.2016.0040.
- [7] Yixin Chen and Li Tu. 2007. Density-based clustering for real-time stream data. In *Proceedings of the 13th ACM SIGKDD international conference on Knowledge discovery and data mining (KDD '07)*. Association for Computing Machinery, New York, NY, USA, 133–142. <https://doi.org/10.1145/1281192.1281210>
- [8] Aljarah, Ibrahim & Faris, Hossam & Mirjalili, Seyedali. (2021). *Evolutionary Data Clustering: Algorithms and Applications*.
- [9] T. Li, A. K. Sahu, A. Talwalkar and V. Smith, "Federated Learning: Challenges, Methods, and Future Directions," in *IEEE Signal Processing Magazine*, vol. 37, no. 3, pp. 50-60, May 2020, doi: 10.1109/MSP.2020.2975749.
- [10] Chengcheng Guo, Bo Zhao, and Yanbing Bai. 2022. DeepCore: A Comprehensive Library for Coreset Selection in Deep Learning. In *Database and Expert Systems Applications: 33rd International Conference, DEXA 2022, Vienna, Austria, August 22–24, 2022, Proceedings, Part I*. Springer-Verlag, Berlin, Heidelberg, 181–195. https://doi.org/10.1007/978-3-031-12423-5_14