

BM531 BÜYÜK VERİ ANALİTİĞİ ÖDEV V



BERKANT KOZAN

25832901024

GAZİ ÜNİVERSİTESİ
FEN BİLİMLERİ ENSTİTÜSÜ

İÇİNDEKİLER

İÇİNDEKİLER.....	2
Karanlık Örüntüler ve Manipülatif Reklam Tespiti: Algoritmik ve Veri Odaklı Yaklaşımlar....	4
ÖZET.....	4
Öne Çıkan Tespit Yaklaşımları	4
1. GİRİŞ	4
2. İLGİLİ ÇALIŞMALAR (LİTERATÜR TARAMASI)	5
2.1. Karanlık Örüntü Taksonomileri ve Kavramsal Çerçeve	5
2.2. Otomatik Karanlık Örüntü Tespiti.....	5
2.3. Tıklama Sahteciliği ve Davranışsal Anomali Tespiti	5
2.4. Çevrimiçi Eşleştirme ve AdWords Problemi.....	6
3. ALGORİTMİK ANALİZ: REKLAM EŞLEŞTİRME, BÜTÇE DİNAMİKLERİ VE KARANLIK ÖRÜNTÜLERİN ETKİSİ	6
3.1. AdWords ve On-line Bipartite Eşleştirme Modeli	6
3.1.1. Modelleme:.....	6
3.1.2. On-line Algoritmalar ve Rekabet Oranı:	6
3.1.3. Öğrenme-Güdümlü Eşleştirme:.....	7
3.2. Karanlık Örüntüler ve CTR/Verimlilik Metriklerinin Bozulması	7
3.2.1. Yerel Metrik Sapması:	7
3.2.2. Adversarial Girdi Senaryosu:	7
3.2.3. Bütçe Tüketim Dinamikleri:.....	7
3.3. Öğrenme-Güdümlü AdWords ve Manipülatif Tasarım	8
4. TESPİT METODOLOJİLERİ.....	8
4.1. NLP ve Metin Tabanlı Sınıflandırma	8
4.1.1. Veri Toplama ve Etiketleme	8
4.1.2. Özellik Çıkarma ve Modelleme:	8
4.1.2.1. Transformer Tabanlı Modeller:	8
4.1.2.2. Klasik ML Yaklaşımları:	8
4.1.3. Değerlendirme ve Sınırlılıklar.....	9
4.2. Çok Modlu (Görsel + Metin) ve Kural/Bilgi Tabanlı Sistemler	9
4.2.1. Ekran Görüntüsü Analizi ve Bilgisayarla Görü.....	9
4.2.2. Büyük Ölçekli Çok Modlu Modeller	9

4.2.3.	Kural ve Bilgi Gdml Yaklaşımlar	9
4.3.	Davranışsal ve Ağ/Dinamik Etkileşim Analizi.....	10
4.3.1.	Tıklama Sahteciliği Tespiti.....	10
4.3.2.	Genel ML Çerçevesi.....	10
4.3.3.	Karanlık Örntler ile Davranışsal Analitik Arasındaki Kpr	10
5.	SONUÇ VE GELECEK ÇALIŞMALAR.....	10
6.	KAYNAKÇA	12

Karanlık Örüntüler ve Manipülatif Reklam Tespiti: Algoritmik ve Veri Odaklı Yaklaşımlar

ÖZET

Bu çalışma, karanlık örüntülerin çevrimiçi reklam ekosistemine entegrasyonunu, AdWords tipi on-line bipartite eşleştirme ve bütçe kısıtlı açık artırma algoritmaları bağlamında tartışmakta; ardından NLP ve çok modlu sınıflandırma ile otomatik tespit mimarilerini ve son olarak tıklama sahteciliği ile kullanıcı etkileşim dinamiklerinin makine öğrenmesi tabanlı analizini incelemektedir. Büyük ölçekli web taramaları karanlık örüntülerin yaygınlığını ve üçüncü taraf “dark pattern-as-a-service” ekosistemini göstermektedir [1] [2] [3] [4] [5] [6]. Transformer tabanlı modeller, bilgisayarla görü ve metin işleme kombinasyonlarıyla; tıklama sahteciliği çalışmaları ise oturum süresi, sayfa sayısı, mouse hareketleri gibi davranışsal özniteliklerle yüksek doğrulukta tespit sağlamaktadır [7] [8] [4] [9] [10] [11] [12]. Makale taslağı, bu bulguları birleştirerek karanlık örüntüleri yalnızca etik bir sorun değil, reklam açık artırma mekanizmalarını, CTR metriklerini ve bütçe harcama dinamiklerini bozan bir optimizasyon ve güvenlik problemi olarak yeniden çerçevelendirmektedir.

Öne Çıkan Tespit Yaklaşımları

Yaklaşım	Veri Türü	Ana Teknikler	Citations
Metin tabanlı	UI metni	BERT/DistilBERT, lojistik regresyon	[7] [6] [10] [12]
Çok modlu (görü+NLP)	Ekran görüntüsü + metin	CV + NLP, MLLM, kural+bilgi tabanlı	[13] [4] [5] [14] [15]
Davranışsal	Tıklama/oturum izleri	RF, ağaç tabanlı, DL (RNN, CNN, DNN)	[8] [9] [11]

Figure 1: Karanlık örüntü ve sahte tıklama tespitinde kullanılan başlıca teknik aileleri

1. GİRİŞ

Karanlık örüntüler, kullanıcı kararlarını hizmet sağlayıcı lehine, çoğu zaman kullanıcı aleyhine yönlendiren arayüz stratejileridir [1] [2] [3] [6] [16] [14]. E-ticaret ve reklam odaklı arayüzlerde bu stratejiler, CTR, dönüşüm oranı ve veri toplama metriklerini optimize etmeyi hedefleyen büyük veri ve algoritmik mekanizmalarla etkileşim içindedir [1] [8] [4] [6] [17]. Buna paralel olarak, PPC (pay-per-click) reklam modellerinde tıklama sahteciliği, bütçe tüketimini ve açık artırma dengesini bozan başka bir manipülatif davranış sınıfı olarak öne çıkmaktadır [8] [9] [11]. Bu makale taslağı, bu iki manipülasyon türünü ortak bir algoritmik çerçevede ele almayı hedefler.

2. İLGİLİ ÇALIŞMALAR (LİTERATÜR TARAMASI)

2.1. Karanlık Örüntü Taksonomileri ve Kavramsal Çerçeve

Büyük ölçekli taramalar, 11K alışveriş sitesi üzerinde 1.818 örnekle 15 tip ve 7 kategori karanlık örüntü belirleyerek taksonomik bir temel sunmuştur [1]. Daha yeni çalışmalar, 64–68 tip içeren daha kapsamlı çerçeveler ve karanlık örüntü analiz iskeletleri (DPAF) önermekte; mevcut tespit araçlarının yalnızca türlerin ~%45–50’sini kapsadığını göstermektedir [2] [3]. Sistemik derlemeler, Obstruction, Sneaking, Interface Interference, Forced Action, Nagging gibi mekanizma aileleri üzerinde geniş uzlaş bulundugunu vurgulamaktadır [6] [16] [14].

Kavramsal düzeyde dört temel unsur öne çıkar: manipülatif niyet, bilgi asimetrisi, seçim alanının kısıtlanması ve bilişsel önyargıların sömürülmesi [16]. Çerez banner’larında, görsel, süreçsel ve dilsel ölçülebilir HCI özniteliklerine dayalı tanımlamalarla, sübjektif yorumun azaltılması ve otomatik tespit için ölçülebilir nitelik listeleri önerilmektedir [14].

2.2. Otomatik Karanlık Örüntü Tespiti

Çok modlu ve metin tabanlı tespit çalışmaları hızla artmaktadır:

- E-ticaret ve genel web arayüzlerinde, BERT/DistilBERT ve lojistik regresyon kullanılarak confirmshaming, roach motel, trick questions gibi bilinen türler üzerinde %75’e varan doğruluk bildirilmiştir [7] [6] [12].
- AidUI, ekran görüntülerinden bilgisayarla görü ve NLP ile görsel ve metinsel ipuçları çıkararak 10 farklı karanlık örüntüyü tespit eder; genel $F1 \approx 0.65$ ve bazı türlerde $F1 > 0.82$ elde eder [13].
- UIGuard, mobil UI’larda bilgisayarla görü + metin eşleştirmeye dayalı bilgi güdümlü bir sistem sunar; 1.660 örneklik veri kümesi üzerinde $F1 \approx 0.79$ ’a ulaşır [4].
- Çok ölçekli veri setleri (6.725 görüntü, 10.421 örnek) üzerine kurulu DPGuard, ticari çok modlu büyük dil modellerinden yararlanarak, mobil ve web uygulamalarının anlamlı bir kısmında (mobilde %25.7, web’de %49.0) en az bir deceptive pattern bulunduğunu göstermiştir [5].
- Sistemik incelemeler, BERT-tabanlı modelleri karanlık örüntü tespitinde en sık kullanılan temel hat olarak rapor eder [6].

Yeni yaklaşımlar, LLM tabanlı URL ve UI analizi [15] ile tarayıcı eklentileri üzerinden gerçek zamanlı tespit ve kullanıcının eğitilmesini hedefleyen BERT tabanlı Chromium uzantılarını birleştirir [10].

2.3. Tıklama Sahteciliği ve Davranışsal Anomali Tespiti

PPC modelindeki tıklama sahteciliği, bot veya kötü niyetli insan tıklamaları ile reklamveren bütçesinin yapay biçimde tüketilmesini içerir [8] [9] [11]. Gerçek kullanıcı gezinme verilerine dayalı çalışmalarda; ziyaret edilen sayfa sayısı, oturum süresi ve gerçekleştirilen eylem sayısı gibi davranışsal öznitelikler çıkarılmış, çeşitli makine öğrenmesi modelleri kıyaslanmıştır [8].

Rastgele orman (Random Forest) algoritmasının, doğruluk ve diğer metriklerde diğer yöntemleri geçtiği raporlanmıştır [8].

Daha kapsamlı bir çalışmada, zengin öznitelik mühendisliği (zaman, tıklayıcı davranışı, ortam/IP, reklamla ilişkili öznitelikler ve mouse_moves gibi etkileşimsel göstergeler) ile 9 farklı ML/DL modeli değerlendirilmiş; ağaç tabanlı yöntemler (DT, RF, Gradient Boosting, LightGBM, XGBoost) %98.9+ doğruluk, DL tarafında ise RNN %97.34 doğruluk seviyesine ulaşmıştır [11]. Diğer bir çalışma, bot-insan ayrımı için çoklu ML modeli geliştirerek benzer şekilde yüksek performans bildirmektedir [9].

2.4. Çevrimiçi Eşleştirme ve AdWords Problemi

Arama motoru reklamcılığında gösterilecek reklamların seçimi, on-line bipartite eşleştirme ve AdWords problemine indirgenebilir [18] [17] [19]. AdWords, çevrimiçi gelen sorgu (impression) tarafı ile bütçeli reklamveren tarafı arasındaki eşleştirme problemidir; amaç, her bir tıklama teklifini (bid) ve reklamveren bütçesini dikkate alarak toplam geliri maksimize etmektir [17] [19].

Klasik on-line bipartite eşleştirme için Ranking algoritmasının optimal rekabet oranını veren metin düzeyinde bir sunum [18], ve AdWords'ü $1-1/e$ rekabet oranıyla çözen optimal algoritmalar [17] mevcuttur. Daha yakın tarihli çalışmalar, öğrenme-güdümlü (learning-augmented) on-line eşleştirme algoritmaları geliştirerek, her iterasyonda önerilen bir eşleştirme tahmininden gelen “advice” ile klasik algoritmaların birleştirilmesi ve robustluk-tutarlılık (robustness-consistency) dengesinin analizi üzerinde durmaktadır [19]. Bu algoritmalar, küçük teklif varsayımı (small bids) altında AdWords problemini de kapsar [19].

3. ALGORİTMİK ANALİZ: REKLAM EŞLEŞTİRME, BÜTÇE DİNAMİKLERİ VE KARANLIK ÖRÜNTÜLERİN ETKİSİ

Bu bölüm, literatürdeki on-line eşleştirme ve AdWords sonuçları temelinde, karanlık örüntüler ve manipülatif davranışların bu algoritmalara nasıl “sızabileceğini” kavramsal ve formel bir bakışla tartışmaya yönelik yapılandırılmalıdır.

3.1. AdWords ve On-line Bipartite Eşleştirme Modeli

3.1.1. *Modelleme:*

- Sol tarafta reklamverenler (bütçeler B_u), sağ tarafta zaman içinde gelen sorgular/impression'lar; kenar ağırlıkları b_{uv} teklifi temsil eder [17] [19].
- Her bir gelen sorgu için algoritma, mevcut bütçe kısıtları altında bir reklamveren seçer; elde edilen gelir, eşleştirme ve kalan bütçelere bağlıdır [17] [19].

3.1.2. *On-line Algoritmalar ve Rekabet Oranı:*

- Ranking ve Balance felsefesine dayalı algoritmalar, ufukta tüm istek sırası bilinmeksizin, en kötü durumda (adversarial sıra) bile optimuma $1-1/e$ oranında yaklaşan çözümler sunar [18] [17].

- Fractional ve integral eşleştirme arasında, küçük teklif varsayımı altında farklı rekabet oranı garantileri mevcuttur [17] [19].

3.1.3. Öğrenme-Güdümlü Eşleştirme:

- Veri güdümlü tahminler (örneğin beklenen CTR veya talep istatistikleri) doğrultusunda her iterasyon için “önerilen eşleştirme” bilgisi sunulur; algoritma bu tavsiye ile klasik algoritmayı karışık strateji şeklinde birleştirir [19].
- Burada hedef, “COINFLIP” gibi kaba yaklaşımlara kıyasla, hem tavsiye doğru olduğunda yüksek verim, hem de tavsiye hatalı olduğunda kabul edilebilir robustluk sunan algoritmalar tasarlamaktır [19].

3.2. Karanlık Örüntüler ve CTR/Verimlilik Metriklerinin Bozulması

Metin ve arayüz düzeyindeki karanlık örüntülerin tipik hedefleri arasında, daha fazla tıklama, daha fazla veri paylaşımı ve daha yüksek satın alma oranı yer alır [1] [2] [3] [4] [5] [6] [10]. Bu durum, AdWords benzeri açık artırma mekanizmalarında iki seviyeli bir bozulmaya yol açabilir:

3.2.1. Yerel Metrik Sapması:

- Karanlık örüntüler, reklamın veya call-to-action’ın tıklanma olasılığını, kullanıcının gerçek ilgisinden bağımsız olarak yükseltir (örneğin “disguised ad”, “trick question”, zorlama buton yerleşimi) [1] [13] [4] [5] [6] [10].
- Bu durumda, CTR tahmin modelleri, tıklamayı ilgi sinyali olarak yanlış etiketler; beklenen gelir tahminleri şişer ve açık artırma algoritması bu reklamlara daha yüksek ağırlık vererek, bütçelerin bu segmentlere kaymasına neden olur.

3.2.2. Adversarial Girdi Senaryosu:

- On-line eşleştirme algoritması, gelen sorgu sırasını kontrol edemez; ancak karanlık örüntü içeren sayfalar, kullanıcı akışını ve tıklama sıklığını değiştirerek fiilen algoritmanın gözlediği “online sıra”yı manipülatif biçimde yeniden şekillendirir [1] [4] [5] [6].
- Böylece, teorik rekabet oranı garantileri, davranışsal tarafın bu tür manipülatif değiştirmelerini “noise” veya adversarial örnekler olarak içermediği için, pratikte etkinliğini kaybedebilir. Bu ilişki, gelecekte formel analiz gerektiren bir araştırma boşluğu olarak işaretlenebilir.

3.2.3. Bütçe Tüketim Dinamikleri:

- Tıklama sahteciliği çalışmaları, sahte tıklamaların bütçeyi hızla tüketerek reklamveren zararına, yayıncı veya dolandırıcı lehine gelir transferi oluşturduğunu göstermektedir [8] [9] [11].
- Karanlık örüntüler üzerinden yapay şekilde teşvik edilen tıklamalar (ikna edilmiş fakat ilgisiz kullanıcılar) ise benzer şekilde reklamveren bütçesini

gerçek dönüşüm potansiyeli düşük kullanıcı segmentlerine yönlendirir. Davranışsal verilerde bu iki fenomenin (fraud vs. manipülatif ama “gerçek” kullanıcı) ayrıştırılması, hem gelir optimizasyonu hem de etik tasarım açısından kritik hale gelir [8] [11] [14].

3.3. Öğrenme-Güdümlü AdWords ve Manipülatif Tasarım

Öğrenme-güdümlü on-line eşleştirme algoritmaları, tahmin modüllerinden gelen tavsiyeye dayanır [19]. Eğer bu tahmin modülleri, karanlık örüntülerin şişirdiği CTR ve dönüşüm metrikleriyle eğitiliyorsa:

- Tavsiye mekanizması, manipülatif arayüzlere sahip reklamverenleri sistematik olarak kayırabilir; bu da hem kullanıcı refahını hem de uzun vadeli pazar verimliliğini bozar [1] [2] [3] [4] [5] [6] [16].
- Robusluk-tutarlılık analizi, yalnızca tahmin hatalarına değil, aynı zamanda tahminlerin kasıtlı veya tasarımsal olarak “adversarial” manipülasyonlara maruz kalmasına karşı da yeniden ele alınmalıdır [19].

Bu noktada, karanlık örüntü tespiti algoritmalarının doğrudan reklam sıralama ve bütçe tahsis mekanizmalarına entegrasyonu (örneğin, deceptive pattern içeren landing page'lere ceza katsayısı verilmesi) yeni bir optimizasyon problemi olarak formüle edilebilir; mevcut literatür, gerekli taksonomik ve tespitsel alt yapıyı sağlamaktadır [1] [2] [13] [4] [5] [6] [14] [12] [15].

4. TESPİT METODOLOJİLERİ

Bu bölüm, üç teknik sütun için ortak bir tespit çerçevesi (veri toplama, özellik çıkarımı, modelleme ve değerlendirme) kurgusuna dayanmalıdır.

4.1. NLP ve Metin Tabanlı Sınıflandırma

4.1.1. Veri Toplama ve Etiketleme

- E-ticaret, sosyal medya ve hizmet sitelerinden otomatik web kazıma ile buton, modal, form ögesi gibi arayüz bileşenlerinin metinleri çıkarılmıştır [7] [6] [10] [12].
- Veri kümeleri, karanlık örüntü türleri (confirmshaming, trick questions, forced continuity vb.) bazında etiketlenmiştir [7] [6] [10] [12].

4.1.2. Özellik Çıkarma ve Modelleme:

4.1.2.1. Transformer Tabanlı Modeller:

- DistilBERT, BERT gibi önceden eğitilmiş dil modelleri, ince ayar (fine-tuning) ile çok sınıflı karanlık örüntü tespitinde kullanılmış; %75 (DistilBERT) [7] ile %97'ye varan doğruluklar (BERT tabanlı uzantı) rapor edilmiştir [6] [10].

4.1.2.2. Klasik ML Yaklaşımları:

- Bag-of-words temsili ve lojistik regresyon, karanlık örüntü metinlerinin yüksek doğrulukla ayırt edilebildiğini göstermektedir [12].

- BERT tabanlı modeller, Random Forest ve SVM'e göre daha yüksek doğruluk sunarken; klasik modeller, yorumlanabilirlik ve hesaplama maliyeti açısından avantajlıdır [6] [10] [12].

4.1.3. Değerlendirme ve Sınırlılıklar

- Doğruluk, precision, recall, F1 ve ROC-AUC gibi metriklerle değerlendirmeler yapılmış; çoğu çalışma veri kümesi dengesizliği ve karanlık örüntü türlerinin çeşitliliği nedeniyle kapsam sınırlı olduğuna dikkat çekmektedir [7] [2] [3] [6] [10] [12].
- Dinamik veya bağlam bağımlı karanlık örüntülerin (örneğin belirli etkileşim sırası gerektiren akışlar) tespiti, yalnızca statik metinle zor; bağlam modelleme ve etkileşim geçmişini gerektirmektedir [7] [13] [4] [14].

4.2. Çok Modlu (Görsel + Metin) ve Kural/Bilgi Tabanlı Sistemler

4.2.1. Ekran Görüntüsü Analizi ve Bilgisayarla Görü

- AidUI, mobil ve web uygulama ekran görüntülerinden görsel ve metinsel ipuçlarını birleştirir; 301 karanlık örüntü örneği içeren ContextDP veri kümesi üzerinde $F1 \approx 0.65$, $IoU = 0.84$ ile örüntüleri lokalize eder [13].
- UIGuard, ikon semantiği, şablon eşleme, durum tanıma ve renk/gruplama modüllerini aşamalı olarak ekleyerek, farklı modül kombinasyonlarının katkısını ablation deneyleri ile analiz eder [4]. Sonuçlar, metin + ikon + renk bilgisi kombinasyonunun doğruluğu artırdığını gösterir [4].

4.2.2. Büyük Ölçekli Çok Modlu Modeller

- DPGuard, 6.725 görüntü ve 10.421 deceptive pattern örneğinden oluşan birleşik veri kümesi üzerinde ticari çok modlu büyük dil modellerini (MLLM) kullanır ve daha önceki yöntemlere kıyasla daha yüksek performans raporlar [5].
- Çalışma, popüler mobil ve web uygulamalarının anlamlı bir oranında en az bir deceptive pattern bulunduğunu ortaya koyar [5].

4.2.3. Kural ve Bilgi GÜdümlü Yaklaşımlar

- UIGuard, entegrasyon için mevcut taksonomilerden çıkarılan bilgiye dayalı kurallar kullanarak, yeni karanlık örüntü türlerinin sisteme görece düşük maliyetle eklenmesini sağlar [4].
- Çerez banner'ları özelinde, görsel/proses/dilsel ölçülebilir özelliklere dayalı tip ve öznitelik eşlemeleri önerilmiştir; bu, otomatik tespit için formelleştirilebilir bir ontoloji imkânı sunar [14].
- Bazı sistemler URL tabanlı analiz, LLM sınıflandırıcılar ve tarayıcı eklentisi entegrasyonu ile kullanıcıya sitedeki karanlık örüntü sayısını ve tipini göstermeyi amaçlar [10] [15].

4.3. Davranışsal ve Ağ/Dinamik Etkileşim Analizi

4.3.1. Tıklama Sahteciliği Tespiti

- Gerçek navigasyon verileri üzerinden, oturumdaki sayfa sayısı, gezinme süresi, kullanıcı eylemleri gibi özellikler çıkarılarak, kullanıcıların insan mı bot mu olduğu sınıflandırılmış; farklı ML modelleri karşılaştırılmış, RF en iyi performansı sağlamıştır [8].
- Zenginleştirilmiş veri kümelerinde; zaman temelli (zaman damgaları, aralıklar), tıklayıcı davranışı (tıklama dizileri, tekrarlayan kalıplar), ortam/IP (proxy, coğrafi anomali), reklamla ilgili (kampanya, slot) ve başka öznitelikler ile ML/DL modelleri değerlendirilmiştir [11].
 - Karar ağacı ve rastgele orman %98.99+ doğruluk; GB, LightGBM, XGBoost %98.90+; RNN %97.34 doğruluk sağlamıştır [11].
 - Feature elimination (örneğin RFE) ile en bilgilendirici öznitelik seti seçilmiş; tıklama desenlerinin ve mouse_moves gibi ince-granüler etkileşim göstergelerinin önemine dikkat çekilmiştir [11].

4.3.2. Genel ML Çerçevesi

- Adım adım çerçeve: veri toplama → ön işleme (oturum rekonstrüksiyonu, anomali ön filtreleme) → özellik çıkarımı (zaman serisi istatistikleri, spektral özellikler, mouse hareket yoğunluğu vb.) → model eğitimi (ağaç tabanlı, RNN/CNN, hibrit ensemble'lar) → çevrimiçi veya near-real-time dağıtım [8] [9] [11].
- Hibrit mimarilerde, CNN/BiLSTM gibi derin özellik çıkarıcılarla, son aşamada RF veya benzeri ağaç tabanlı sınıflandırıcıların birleştirilmesinin çok yüksek doğruluk ve recall sunduğu gösterilmiştir [11].

4.3.3. Karanlık Örüntüler ile Davranışsal Analitik Arasındaki Köprü

- UIGuard ve DPGuard gibi çalışmalar, kullanıcı algısının dinamik yönünü, kullanıcı çalışmaları ve algı testleriyle inceleyerek; insanlar için “normal” sayılan UI kararları ile kasıtlı karanlık örüntüler arasındaki sınırın bulanıklaştığını göstermektedir [4] [5].
- Kullanıcı anketleri, çoğu katılımcının karanlık örüntüleri fark etmekte zorlandığını; tespit araçlarıyla eğitimin algıyı anlamlı ölçüde geliştirdiğini rapor eder [4] [10].
- Bu bulgular, davetsiz tıklamalar ve karanlık örüntü kaynaklı “yarı-zorlanmış” tıklamaların ayrıştırılmasının, sadece teknik değil aynı zamanda algısal ve deneysel bir konu olduğunu ortaya koyar [4] [5] [10] [14].

5. SONUÇ VE GELECEK ÇALIŞMALAR

Bu makale taslağı, karanlık örüntüler ve manipülatif reklam tespitini, on-line bipartite eşleştirme ve AdWords algoritmalarından, transformer tabanlı çok modlu tespit mimarilerine ve davranışsal anomali analizine kadar uzanan bir teknik spektrumda konumlandırmaktadır. Mevcut çalışmalar, geniş ve ayrıntılı taksonomiler, yüksek performanslı NLP ve bilgisayarla görü temelli tespit sistemleri ve tıklama sahteciliği için güçlü ML/DL modelleri sunmaktadır.

Bununla birlikte, karanlık örüntü tespiti araçlarının kapsadığı örüntü türleri hâlen sınırlı; dinamik, bağlamsal ve iş akışı düzeyindeki manipölasyonların sistematik olarak ele alınmasına ihtiyaç vardır [2] [3] [4] [5] [14].

Gelecek çalışmalar için öne çıkan hatlar;

- (i) Karanlık örüntü skorlarının doğrudan reklam sıralama ve bütçe optimizasyon algoritmalarına entegre edildiğı, kullanıcı refahı kısıtları içeren yeni AdWords varyantlarının formelleştirilmesi;
- (ii) Davranışsal izler, ağ yapıları ve UI sinyallerini bir araya getiren birleşik, çok modlu tespit modelleri;
- (iii) Ölçülebilir HCI özniteliklerine dayalı, regölasyon dostu, şeffaf ve denetlenebilir tespit çerçevelerinin geliştirilmesidir. Bu doğrultuda, karanlık örüntüler teknik ve politik-ekonomik boyutları birleştiren zengin bir büyük veri optimizasyon problemi olarak araştırmaya açıktır.

6. KAYNAKÇA

- [1] Mathur A, Acar G, Friedman M, et al. Dark Patterns at Scale. *Proceedings of the ACM on Human-Computer Interaction*. 2019;3:1 - 32. doi:10.1145/3359183
- [2] Nie L, Zhao Y, Li C, Luo X, Liu Y. Shadows in the Interface: A Comprehensive Study on Dark Patterns. *Proceedings of the ACM on Software Engineering*. 2024;1:204 - 225. doi:10.1145/3643736
- [3] Li M, Wang X, Nie L, et al. A Comprehensive Study on Dark Patterns. *ArXiv*. 2024;abs/2412.09147. doi:10.48550/arxiv.2412.09147
- [4] Chen J, Sun J, Feng S, et al. Unveiling the Tricks: Automated Detection of Dark Patterns in Mobile Applications. *Proceedings of the 36th Annual ACM Symposium on User Interface Software and Technology*. 2023. doi:10.1145/3586183.3606783
- [5] Shi Z, Sun R, Chen J, et al. 50 Shades of Deceptive Patterns: A Unified Taxonomy, Multimodal Detection, and Security Implications. *Proceedings of the ACM on Web Conference 2025*. 2025. doi:10.1145/3696410.3714593
- [6] Thukral A, Aggarwal N, Garg AS, Lipika L. A Systematic Review on Dark Patterns: Whisper in Clicks, Hide in Links. *International Journal of Global Research Innovations & Technology*. 2025. doi:10.62823/ijgrit/03.03.7864
- [7] Rajput K, Singh S, R K, S S, T V. Dark Pattern Detection on Web Page using DistilBERT. *2025 IEEE First International Conference on Innovations in Engineering and Next-Generation Technologies for Sustainability (ICINVENTS)*. 2025;1:1-6. doi:10.1109/icinvents64613.2025.11401672
- [8] Aljabri M, Mohammad R. Click fraud detection for online advertising using machine learning. *Egyptian Informatics Journal*. 2023. doi:10.1016/j.eij.2023.05.006
- [9] Mahesh V, Chandra KVS, Babu LSP, Sowjanya V, Mohammed M. Clicking Fraud Detection for online advertising using Machine Learning. *2023 4th International Conference on Intelligent Technologies (CONIT)*. 2024. doi:10.1109/conit61985.2024.10627189
- [10] Vedhapriyavadhana R, Bharti P, Chidambaranathan S. Detecting dark patterns in shopping websites – a multi-faceted approach using Bidirectional Encoder Representations From Transformers (BERT). *Enterprise Information Systems*. 2025;19. doi:10.1080/17517575.2025.2457961
- [11] Alzahrani RA, Aljabri M, Mohammad RMA. Ad Click Fraud Detection Using Machine Learning and Deep Learning Algorithms. *IEEE Access*. 2025;13:12746-12763. doi:10.1109/access.2025.3532200
- [12] Umar A, Lawan M, Lawan A, Abdulkadir A, Dahiru M. Detecting Dark Patterns in User Interfaces Using Logistic Regression and Bag-of-Words Representation. *ArXiv*. 2024;abs/2412.14187. doi:10.48550/arxiv.2412.14187
- [13] Mansur SHM, Salma S, Awofisayo D, Moran K. AidUI: Toward Automated Recognition of Dark Patterns in User Interfaces. *2023 IEEE/ACM 45th International Conference on Software Engineering (ICSE)*. 2023. doi:10.1109/icse48619.2023.00166

- [14] Kocyigit E, Rossi A, Lenzini G. A Systematic Approach for A Reliable Detection of Deceptive Design Patterns Through Measurable HCI Features. *Proceedings of the 2024 European Symposium on Usable Security*. 2024.
doi:10.1145/3688459.3688475
- [15] Babu SBDSKK, Nithin BSNBS, Raghuram E, Bharath A, S. Dark Surfer-A Dark Pattern Analyzer & Classifier. *ITM Web of Conferences*. 2025.
doi:10.1051/itmconf/20257401018
- [16] Meirezaldi O. Dark Patterns Reconsidered: A Cross-Taxonomic and Conceptual Mapping for Ethical Interface Design. *Telaah Bisnis*. 2025.
doi:10.35917/tb.v26i1.586
- [17] Mehta A, Saberi A, Vazirani U, Vazirani V. AdWords and generalized on-line matching. *46th Annual IEEE Symposium on Foundations of Computer Science (FOCS'05)*. 2005. doi:10.1145/1284320.1284321
- [18] Vazirani V. Online Bipartite Matching and Adwords. 2021.
- [19] Choo D, Jin B, Shin Y. Learning-Augmented Online Bipartite Fractional Matching. *ArXiv*. 2025;abs/2505.19252. doi:10.48550/arxiv.2505.19252