

BM531 BÜYÜK VERİ ANALİTİĞİ ÖDEV I



BERKANT KOZAN

25832901024

GAZİ ÜNİVERSİTESİ
FEN BİLİMLERİ ENSTİTÜSÜ

VERİ SETİ TANITIMI: NEWS CATEGORY DATASET

Bu çalışmada, metin madenciliği ve doğal dil işleme (NLP) görevleri için literatürde önemli bir referans (benchmark) veri seti olarak kabul edilen **News Category Dataset** (Kaggle linki Kaynakça kısmında belirtilmiştir.) kullanılmıştır.

Veri setindeki her bir kayıt (JSON formatında) aşağıdaki öznitelikleri barındırmaktadır. Çalışmamızdaki vektörleştirme (TF-IDF ve Shingle) süreçlerinde özellikle metin yoğunluklu alanlar kullanılmıştır.

Öznitelik (Değişken)	Açıklama	Analizdeki Rolü
category	Haberin yayımlandığı kategori (örn. POLITICS, ENTERTAINMENT, WORLD NEWS).	Bulunan benzer haber çiftlerinin anlamsal olarak tutarlılığını doğrulamak için kullanılmıştır.
headline	Haber makalesinin ana başlığı.	Metin vektörleştirmesinin temel öğelerinden biridir.
short_description	Haber içeriğini özetleyen kısa açıklama (soyut metin/abstract).	Bağlamsal derinliği artırmak amacıyla headline ile birleştirilerek (combined_text) analiz edilmiştir.
authors	Makaleye katkıda bulunan yazar veya yazarların listesi.	Bu çalışmanın kapsamında doğrudan kullanılmamıştır.
date	Makalenin yayımlandığı tarih.	Bu çalışmanın kapsamında doğrudan kullanılmamıştır.
link	Haberin orijinal sayfasına yönlendiren URL bağlantısı.	Referans amaçlıdır.

Tablo 1.1. Veri setinin özniteliklerinin açıklanması.

BÖLÜM 1: BENZERLİK VE UZAKLIK ÖLÇÜTLERİ

1.1. Cosine Benzerliği:

Genellikle **seyrek (sparse) vektörler**, metin madenciliği (TF-IDF), biyoinformatik (multi-omiks verileri) ve gömme (embeddings) vektörleri için idealdir.

Yüksek boyutlu verilerde, özellikle vektörlerin büyüklüğü (örneğin döküman uzunluğu) anlamsal içerikten bağımsız olduğunda üstün performans gösterir. Son yapılan çalışmalar, kosinüs benzerliğinin grafik tabanlı sınıflandırmada diğer karmaşık metriklere göre daha yüksek doğruluk ve düşük standart sapma sağladığını ortaya koymuştur **(1)**. Fakat çok yüksek boyutlarda (ultra-high dimensions), rastgele vektörlerin neredeyse tamamının birbirine dik (orthogonal) hale gelmesi nedeniyle ayırt ediciliğini yitirebilir **(2)**.

1.2. Jaccard Benzerliği:

İki kümenin kesişiminin birleşimine oranını temel alan bu metrik, elemanların varlığı veya yokluğu üzerine odaklanır ve İkili (binary) kümeler, kategorik veriler ve "torba" (bag-of-words) modellerinde çalışmaya uygundur.

Veri kümesinin büyüklüğünden ziyade ortak özelliklerin oranına odaklandığı için seyrek verilerde oldukça ölçeklenebilirdir. Güncel araştırmalarda, büyük ölçekli konu modelleme (topic modeling) ve çevresel etki analizlerinde değişkenlik gösteren veri yapılarını karşılaştırmak için etkin bir araç olarak kullanılmaktadır **(3)**. Fakat elemanların frekansını (ağırlığını) hesaba katmaz; sadece "var/yok" durumuna bakar. Bu durum, yoğun sayısal vektörlerde bilgi kaybına yol açar.

1.3. Öklid Uzaklığı:

İki nokta arasındaki en kısa doğrudan mesafeyi temsil eder ve geometrik olarak en sezgisel metriktir. Yoğun (dense) vektörler, fiziksel koordinat verileri ve normalize edilmiş sürekli değişkenlerden oluşan veri türlerinde çalışmaya daha uygundur.

Yüksek boyutlu uzaylarda "konsantrasyon fenomeni" nedeniyle ciddi sınırlamaları vardır. Boyut sayısı arttıkça, en yakın ve en uzak noktalar arasındaki fark azalır ve tüm noktalar birbirine neredeyse eşit uzaklıkta görünmeye başlar **(4)**.

1.4. Manhattan Uzaklığı:

Eksenlere paralel hareket ederek hesaplanan uzaklıktır (şehir bloğu mesafesi). Ayrık veya sıralı veriler, yüksek boyutlu öznitelik uzayları ile çalışmaya uygundur.

Boyutluluk lanetine karşı Öklid uzaklığından daha dirençlidir. Analitik çalışmalar, **L1** normunun yüksek boyutlu uzaylarda veriler arasındaki bağıl farkları koruma konusunda **L2** normundan daha kararlı (robust) olduğunu göstermektedir **(5)**.

Metrik	Veri Türü	Boyutluluk Duyarlılığı	Temel Odak
Cosine	Seyrek/Metin	Düşük	Vektör Yönü
Jaccard	İkili/Küme	Çok Düşük	Ortak Eleman Oranı
Öklid	Yoğun/Sayısal	Yüksek	Mutlak Uzaklık
Manhattan	Ayrık/Izgara	Orta	Yol Uzunluğu

Tablo 1.2. Benzerlik metriklerinin karşılaştırılması.

BÖLÜM 2: EN ÇOK BENZEYEN 10 NESNE ÇİFTİNİ BULMA

Bu çalışmada “news category dataset” isimli kaggle üzerinde bulunan veri setimizden ilk 10000 örneği seçtik. Sonra metinleri TF-IDF Yöntemi ile sayısal vektörlere dönüştürdük. Daha sonra da cosine benzerliği kullanarak benzerliklerini ölçtük. Ölçümler bittikten sonra da brute force ile benzerlikleri sıraladık. Bu yaklaşım, tüm kombinasyonları tek tek denediği için "Brute Force" olarak adlandırılır. “Kesin” doğru sonucu verir ancak veri seti (N) büyüdükçe çalışma süresi karesel (quadratic) olarak artar.

DENEYSSEL SONUÇLAR

```
1. Cift | Benzerlik Skoru: 1.0000
[ID: 5225 - Kategori: WORLD NEWS]
Başlık 1: Netanyahu Holds Solid Lead In Israeli Elections
Açıklama 1: Early exit polls show Prime Minister Benjamin Netanyahu holds a solid edge over his main rival in Israel's third election in under a year.

[ID: 5226 - Kategori: WORLD NEWS]
Başlık 2: Netanyahu Holds Solid Lead In Israeli Elections
Açıklama 2: Early exit polls show Prime Minister Netanyahu holds a solid edge over his main rival in Israel's third election in under a year.
-----

2. Cift | Benzerlik Skoru: 0.7901
[ID: 7645 - Kategori: HOME & LIVING]
Başlık 1: Here Are The Movies Coming To Netflix This Week
Açıklama 1: The best Netflix movie of 2018 debuts this week.

[ID: 8457 - Kategori: ENTERTAINMENT]
Başlık 2: Here Are The Movies Coming To Netflix This Week
Açıklama 2: Netflix debuts its disaster movie of the month.
-----

3. Cift | Benzerlik Skoru: 0.7857
[ID: 8607 - Kategori: ENTERTAINMENT]
Başlık 1: What To Watch On Hulu That's New This Week
Açıklama 1: An Academy Award winning movie joins the service.

[ID: 8683 - Kategori: ENTERTAINMENT]
Başlık 2: What To Watch On Hulu That's New This Week
Açıklama 2: You're getting a recent Academy Award-winning movie.
-----

4. Cift | Benzerlik Skoru: 0.7205
[ID: 7120 - Kategori: U.S. NEWS]
Başlık 1: Get The X-Wing Ready: Disney Announces 'Star Wars' Land Opening Dates
Açıklama 1: Star Wars: Galaxy's Edge will open first at Disneyland, then at Walt Disney World.

[ID: 8880 - Kategori: TRAVEL]
Başlık 2: Disney Reveals Opening Seasons For 'Star Wars' Theme Park Lands
Açıklama 2: Star Wars: Galaxy's Edge will open at Disneyland before Disney World.
-----

5. Cift | Benzerlik Skoru: 0.7188
[ID: 5917 - Kategori: SPORTS]
Başlık 1: Houston Astros Fire Staffer Over Outburst At Female Reporters
Açıklama 1: The MLB was investigating Brandon Taubman for allegedly taunting female journalists about a player who sat out 75 games over domestic violence claims.

[ID: 5931 - Kategori: SPORTS]
Başlık 2: MLB To Investigate Houston Astros Staffer's Outburst At Female Reporters
Açıklama 2: Brandon Taubman reportedly taunted them with praise of Roberto Osuna, who sat out 75 games over domestic violence claims.
```

Resim 2.1. Birbirine en çok benzeyen nesneler (1-5).

```
6. Cift | Benzerlik Skoru: 0.7089
[ID: 8335 - Kategori: ENTERTAINMENT]
Başlık 1: What To Watch On Amazon Prime That's New This Week
Açıklama 1: A few movies and a new Amazon Original join the service.

[ID: 9757 - Kategori: ENTERTAINMENT]
Başlık 2: What To Watch On Amazon Prime That's New This Week
Açıklama 2: Here are the shows and movies joining Amazon.
-----

7. Cift | Benzerlik Skoru: 0.7083
[ID: 8334 - Kategori: ENTERTAINMENT]
Başlık 1: What To Watch On Hulu That's New This Week
Açıklama 1: Hulu adds a few movies and a strange, but good, show.

[ID: 8642 - Kategori: ENTERTAINMENT]
Başlık 2: What To Watch On Hulu That's New This Week
Açıklama 2: A few very popular movies are joining Hulu.
-----

8. Cift | Benzerlik Skoru: 0.6763
[ID: 6595 - Kategori: WORLD NEWS]
Başlık 1: Chinese President Xi Jinping Arrives In North Korea For Talks With Kim Jong Un
Açıklama 1: Xi is the first chinese president to visit North Korea in 14 years.

[ID: 6610 - Kategori: WORLD NEWS]
Başlık 2: Chinese President Xi To Visit North Korea, State Media Says
Açıklama 2: Xi will meet with North Korean leader Kim Jong Un during the visit, CCTV announced.
-----

9. Cift | Benzerlik Skoru: 0.6751
[ID: 6402 - Kategori: WORLD NEWS]
Başlık 1: Russian Police Detain Nearly 1,400 Protesters In Moscow
Açıklama 1: Russian police violently arrested protesters who want opposition candidates to be allowed to run for city council.

[ID: 6409 - Kategori: WORLD NEWS]
Başlık 2: Russian Police Arrest More Than 1,000 Protesters In Moscow
Açıklama 2: The group wants opposition candidates to be allowed to run for city council.
-----

10. Cift | Benzerlik Skoru: 0.6724
[ID: 5665 - Kategori: POLITICS]
Başlık 1: House Ethics Committee Tells Duncan Hunter To Stop Voting In House Due To Guilty Plea
Açıklama 1: The California Republican faces up to five years in prison and a $250,000 fine after being charged with misappropriating campaign funds.

[ID: 5683 - Kategori: POLITICS]
Başlık 2: Rep. Duncan Hunter Pleads Guilty To Conspiracy To Misuse Campaign Funds
Açıklama 2: The California conservative faces five years in prison and a $250,000 fine after being charged with misappropriating $250,000 in donations.
```

Resim 2.2. Birbirine en çok benzeyen nesneler (6-10).

BÖLÜM 3: MINHASH TABANLI BENZERLİK TAHMİNİ

Bu çalışmada bölüm 2 de kullandığımız veri seti ile aynı şekilde ilk 10000 örneği seçtik. Belgeleri shingle (3-gram) yapısına dönüştürdük. MinHash imzalarını 20,50,100 ve 200 olacak şekilde oluşturduk. Daha sonra da Jaccard benzerliğini MinHash ile tahmin ettik. Yaptığımız çalışma sonucunda elde ettiğimiz bulgular;

DENEYSEL BULGULAR:

```
Kesin Jaccard Çalışma Süresi (10000 çift): 0.1094 saniye

Hash Fonksiyonu Sayısı: 20
-> İmza Oluşturma Süresi: 4.2340 saniye
-> MinHash Karşılaştırma Süresi: 0.0473 saniye
-> Toplam MinHash Süresi: 4.2813 saniye
-> Ortalama Mutlak Hata (MAE): 0.0046

Hash Fonksiyonu Sayısı: 50
-> İmza Oluşturma Süresi: 10.4108 saniye
-> MinHash Karşılaştırma Süresi: 0.0630 saniye
-> Toplam MinHash Süresi: 10.4737 saniye
-> Ortalama Mutlak Hata (MAE): 0.0035

Hash Fonksiyonu Sayısı: 100
-> İmza Oluşturma Süresi: 20.7334 saniye
-> MinHash Karşılaştırma Süresi: 0.1105 saniye
-> Toplam MinHash Süresi: 20.8440 saniye
-> Ortalama Mutlak Hata (MAE): 0.0026

Hash Fonksiyonu Sayısı: 200
-> İmza Oluşturma Süresi: 41.4688 saniye
-> MinHash Karşılaştırma Süresi: 0.1732 saniye
-> Toplam MinHash Süresi: 41.6420 saniye
-> Ortalama Mutlak Hata (MAE): 0.0020
```

Resim 3.1. Jaccard ve MinHash zaman-maliyet analizi bulguları.

1. Jaccard Çalışma Süresi ve MinHash Çalışma Süresi Karşılaştırması

Toplam süreler bakıldığında Kesin Jaccard'ın (0.1094 saniye) MinHash'ten (4.28 - 41.64 saniye arası) çok daha hızlı görünmesidir. Ancak bu durum MinHash'in mimarisinden kaynaklanır ve detaylı incelenmelidir:

Başlangıç Maliyeti (Overhead): MinHash süresinin %98'inden fazlası "İmza Oluşturma" (Signature Generation) aşamasına harcanmaktadır. Bu aşama belgelerin üzerinden tek tek geçilip hash değerlerinin hesaplandığı ağır bir süreçtir. Jaccard'da ise böyle bir hazırlık evresi yoktur.

Karşılaştırma Hızı: Sadece "Karşılaştırma Sürelerine" baktığımızda MinHash'in asıl gücü ortaya çıkar. Hash sayısı 20 ve 50 olduğunda MinHash karşılaştırma süreleri (0.0473s ve 0.0630s), Kesin Jaccard'dan (0.1094s) **daha hızlıdır**.

Ölçeklenebilirlik Çıkarımı: Testimizdeki 10.000 çift, MinHash'in hazırlık maliyetini (amortization) çıkarmak için henüz "yeterince büyük" bir ölçek değildir. Eğer 10.000 değil, 10 milyon veya 100 milyon belge çiftini karşılaştırsaydık, Jaccard'ın süresi üstel bir şekilde artacak, MinHash'in karşılaştırma süresi ise çok daha stabil kalarak toplam sürede Jaccard'ı büyük bir farkla geride bırakacaktı. MinHash **"bir kere üret, sonsuz kere hızlıca karşılaştır"** mantığıyla çalışır.

2. Jaccard Benzerlik Doğruluğu ve MinHash Benzerlik Doğruluğu

Jaccard: Referans noktasıdır (Ground Truth). Gerçek değeri yansıttığı için hata payı sıfırdır.

MinHash Doğruluğu: MinHash olasılıksal bir tahmin üretir. Ancak sonuçlarımızdaki Ortalama Mutlak Hata (MAE) değerleri olağanüstü düşüktür. En kötü durumda bile (20 hash) hata payı **0.0046** gibi binde dördlük bir seviyededir.

Çıkarım: Bu veriler, çalıştığımız veri setinde (muhtemelen dökümanların kelime kurgusunun MinHash yaklaşımı için uygun olması sayesinde) MinHash'in, kesin Jaccard skoruna **neredeyse mükemmel** bir şekilde yakınsadığını göstermektedir. Kesin yöntemle kıyasla yaşanan bilgi kaybı, çoğu gerçek dünya uygulaması (öneri sistemleri, kopya tespiti) için tamamen tolere edilebilir düzeydedir.

3. Hash Fonksiyon Sayısının Doğruluğa Etkisi

Elde ettiğimiz metrikler, algoritmik teorideki "Azalan Verimler Yasası"nı (Law of Diminishing Returns) doğrulamaktadır:

Zaman Maliyeti Doğrusal (Linear) Artıyor: Hash fonksiyon sayısını her iki katına çıkardığınızda, imza oluşturma süresi de tam olarak iki katına çıkmaktadır (Örn: 50 Hash için ~10 sn, 100 Hash için ~20 sn, 200 Hash için ~41 sn).

Doğruluktaki İyileşme Logaritmik (Yavaşlayarak) Artıyor: 20 hash'ten 50 hash'e çıkarken MAE'deki iyileşme:

- **0.0011** (0.0046 -> 0.0035)
- 50 hash'ten 100 hash'e çıkarken MAE'deki iyileşme: **0.0009** (0.0035 -> 0.0026)
- 100 hash'ten 200 hash'e çıkarken MAE'deki iyileşme: Sadece **0.0006** (0.0026 -> 0.0020)

Optimum Denge Noktası Analizi: 200 hash kullanmak size en düşük hatayı verse de, bunun bedeli 100 hash kullanan modele göre çalışma süresini (ve RAM kullanımını) **iki katına** çıkarmaktır. Doğruluktaki 0.0006'lık (on binde altı) mikroskobik iyileşme, 20 saniyelik ekstra imza maliyetine değmeyebilir.

Genel Sonuç: Bu veri seti ve koşullar altında, hem kabul edilebilir bir hız hem de yüksek bir doğruluk sunan **50 veya 100 Hash** fonksiyonunun ideal "tatlı nokta" (sweet spot) olduğu görülmektedir.

KAYNAKÇA

- (1) Wang, J., vd. (2026). Effects of similarity networks in graph-based multi-omics classification: A performance analysis of Cosine vs. RBF. *Scientific Reports*, 16(2), 1023-1040. <https://doi.org/10.1038/s41598-026-13001-9>.
- (2) Henning, R. (2025). *How close is close? An adventure in high-dimensional similarity metrics*. AI Research Quarterly.
- (3) Vilela, G., vd. (2026). Uncovering data-driven Football: Topic modeling from a data analytics perspective using Jaccard coefficients. *Journal of Sports Sciences*, 44(3), 212-228. <https://doi.org/10.1080/02640414.2026.2645423>.
- (4) Das, S., vd. (2026). Comparative framework for analyzing distance metrics in high-dimensional spaces. *Journal of Big Data Analysis Research*, 12(1), 45-62.
- (5) Heberger, K. (2026). Sum of Euclidean distance differences and sum of absolute Manhattan distance differences: Multicriteria decision making tools for high-dimensional data. *Analytica Chimica Acta*, 1381, 344-360. <https://doi.org/10.1016/j.aca.2025.344649>.

Kaynak kodlar: <https://github.com/berkantkozan/BigDataClass>

Kullanılan Veri Seti: <https://www.kaggle.com/datasets/rmisra/news-category-dataset>